适用于基因组学的 FlexPod

FlexPod

NetApp
May 25, 2022

This PDF was generated from https://docs.netapp.com/zh-cn/flexpod/healthcare/flexpod-genomics-introduction.html on May 25, 2022. Always check docs.netapp.com for the latest.

目录

适用于基因组学的 FlexPod . . . 1
TR-4911： FlexPod 基因组学 . . . 1
在 FlexPod 上部署基因组工作负载的优势 . . . 3
解决方案基础架构硬件和软件组件 . . . 6
基因组学— GATK 设置和执行 . . . 10
使用 JAR 文件执行 GATK 的输出 . . . 19
使用 ./gatk 脚本执行 GATK 的输出 . . . 22
使用 Cromwell 引擎执行 GATK 的输出 . . . 24
GPU 设置 . . . 28
结论 . . . 37

适用于基因组学的 FlexPod

TR-4911： FlexPod 基因组学

NetApp 公司 JayaKishore Esanakula

在医疗保健和生命科学方面，与基因组学相比，医学领域更重要的领域很少，而基因组学正在迅速成为医生和护士的重要临床工具。基因组学与医学影像和数字病理学相结合，可帮助我们了解患者的基因可能会受到治疗协议的影响。基因组学在医疗保健领域的成功越来越取决于大规模数据互操作性。最终目标是，了解大量基因数据，确定临床相关的相关性和变体，以改进诊断并实现精准医学。基因组学有助于我们了解疾病爆发的起源，疾病的演变以及哪些治疗方法和策略可能会很有效。显然，基因组学具有许多涵盖预防，诊断和治疗的优势。医疗保健组织正在努力应对多种挑战，其中包括：

- 提高护理质量
- 基于价值的维护
- 数据爆炸式增长
- 精确医学
- 大流行病
- 可穿戴设备，远程监控和护理
- 网络安全

标准化的临床途径和临床协议是现代医学的重要组成部分之一。标准化的一个关键方面是护理提供商之间的互操作性，不仅对于医疗记录，而且对于基因组数据。一个大问题是，医疗保健组织是否会放弃对基因组数据的所有权，而不是让患者拥有其个人基因组数据和相关医疗记录？

可互操作的患者数据是实现精准医疗的关键，而精准医疗是近期数据激增背后的推动力之一。精准医疗的目标是提高健康维护，疾病预防，诊断和治疗解决方案的有效性和准确性。

数据增长率呈指数级增长。2021 年 2 月初，美国实验室每周对大约 8 ， 000 个 COVID-19 型菌种进行了排序。截至 2021 年 4 月，按顺序排列的基因组数量已增加到每周 29 ， 000 个。每个完全序列化的人类基因组的大小约为 125 GB 。因此，按每周排序 29 ， 000 个基因组的速率，剩余的总基因组存储每年将超过 180 PB 。许多国家 / 地区已承诺为基因组流行病提供资源，以改进基因组监控并为应对下一波全球健康挑战做好准备。

基因组研究成本的降低正在以前所未有的速度推动基因测试和研究。这三个 PS 处于转折点：计算机电源，数据隐私和医学个性化。到 2025 年，研究人员估计将对 1 亿到 20 亿个人类基因组进行测序。要使基因组学发挥效用并成为一项有价值的主张，基因组学功能必须是护理工作流的无缝组成部分；它应该易于访问，并可在患者就诊期间执行操作。同样重要的是，将患者电子病历数据与患者基因组学数据集成在一起。随着 FlexPod 等一流的融合基础架构的出现，企业可以将其基因组功能融入医生，护士和诊所经理的日常工作流中。有关最新的 FlexPod 平台信息，请参见此 "采用 Cisco UCS X 系列的 FlexPod Datacenter 白皮书"。

对于医生来说，基因组学的真正价值包括精准医学和基于患者基因组数据的个性化治疗计划。过去临床医生和数据科学家之间从未有过这样的协同作用，基因组学也从最近的技术创新以及医疗保健组织与行业技术领导者之间的真正合作中受益。

学术医疗中心和其他医疗保健和生命科学组织正在努力建立基因组科学卓越中心（ Center of excellence ， COE ）。据Charlie Gersbach 博士Greg Crawford 和Duke 大学的 Tim E Reddy 说： " 我们知道，基因不是通过简单的二进制开关打开或关闭的，而是由多个协同工作的基因监管开关造成的。" 他们还确定 " 基因组的这些部分都不是孤立地工作的。基因组是一个非常复杂的网络，它是进化所交织的 " （ "ref"）。

10 多年来， NetApp 和 Cisco 一直在努力逐步改进 FlexPod 平台。所有客户反馈都会得到倾听，评估，并与 FlexPod 中的价值流和功能集相关联。正是这一持续的反馈，协作，改进和庆祝活动循环让 FlexPod 在全球范围内成为值得信赖的融合基础架构平台。它经过全面简化和设计，成为医疗保健组织最可靠，最强大，最灵活的平台。

范围

借助 FlexPod 融合基础架构平台，医疗保健组织可以托管一个或多个基因组工作负载以及其他临床和非临床医疗保健应用程序。本技术报告在 FlexPod 平台验证期间使用了一种名为 GATK 的开源行业标准基因组学工具。但是，本文档不会深入探讨基因组学或 GATK 。

audience

本文档面向医疗保健行业的技术主管以及 Cisco 和 NetApp 合作伙伴解决方案工程师和专业服务人员。NetApp 假定读者已很好地了解计算和存储规模估算概念，并在技术上熟悉医疗保健威胁，医疗保健安全，医疗保健 IT 系统， Cisco UCS 和 NetApp 存储系统。

在 FlexPod 上部署的医院功能

一家典型的医院拥有多种多样的 IT 系统。大多数此类系统都是从供应商购买的，而很少有系统是由医院内部系统构建的。因此，医院系统必须管理其数据中心的多样化基础架构环境。当医院将其系统统一为 FlexPod 等融合基础架构平台时，企业可以将其数据中心运营标准化。借助 FlexPod ，医疗保健组织可以在同一平台上实施临床和非临床系统，从而统一数据中心运营。

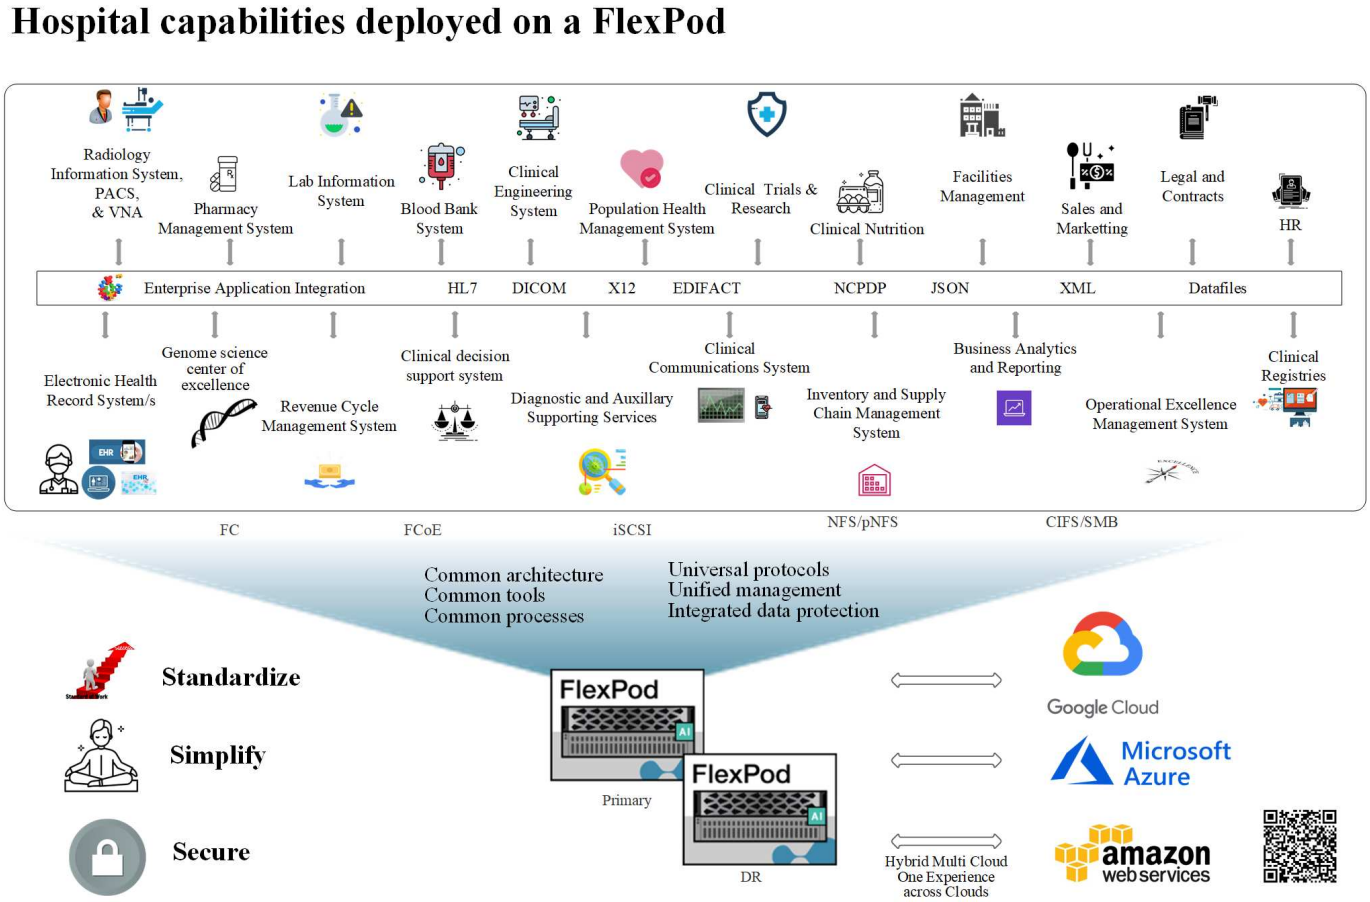

"接下来：在 FlexPod 上部署基因组工作负载的优势。"

在 FlexPod 上部署基因组工作负载的优势

"上一页：简介。"

本节简要列出了在 FlexPod 融合基础架构平台上运行基因组工作负载的优势。我们来快速介绍一下医院的功能。以下业务架构视图显示了一家医院在混合云就绪 FlexPod 融合基础架构平台上部署的功能。

- * 避免医疗保健孤岛。 * 医疗保健孤岛是一个非常值得关注的问题。各个部门往往不是根据自己的选择而是按照演变过程有机地孤立到自己的一组硬件和软件中。例如，放射学，心脏病学， EHR ，基因组学， 分析，收入周期和其他部门最终会获得各自的一套专用软件和硬件。医疗保健组织拥有一组有限的 IT 专业人员来管理其硬件和软件资产。当这组人需要管理一组非常多样化的硬件和软件时，就会出现转折点。供应商为医疗保健组织提供的一系列流程不一致，使异构性变得更加糟糕。
- * 从小规模入手，然后不断增长。 * GATK 工具套件专为 CPU 执行而设计，最适合 FlexPod 等平台。FlexPod 支持网络，计算和存储的独立可扩展性。从小规模入手，随着您的基因组功能和环境增长进行扩展。医疗保健组织无需投资专用平台即可运行基因组工作负载。相反，企业可以利用 FlexPod 等多种平台在同一平台上运行基因组学和非基因组工作负载。例如，如果儿科部门希望实施基因组学功能， IT 领导层可以在现有 FlexPod 实例上配置计算，存储和网络。随着基因组业务部门的发展，医疗保健组织可以根据需要扩展其 FlexPod 平台。
- * 单一控制窗格和无与伦比的灵活性。 * Cisco Intersight 通过将应用程序与基础架构相连接，从裸机服务器和虚拟机管理程序到无服务器应用程序提供可见性和管理，从而显著简化 IT 运营，从而降低成本并降低风险。此统一 SaaS 平台采用统一的开放式 API 设计，可与第三方平台和工具本机集成。此外，它还允许您的数据中心运营团队在现场或任何位置使用移动应用程序进行管理。

  用户可以利用 Intersight 作为管理平台，快速释放环境中的有形价值。Intersight 可以为许多日常手动任务实现自动化，从而消除错误并简化日常操作。此外，借助 Intersight 提供的高级支持功能，采用者可以提前解决问题并加快问题描述解决速度。综合来看，企业在应用程序基础架构上花费的时间和资金远远少于在核心业务开发上花费的时间和资金。

  利用 Intersight 管理和 FlexPod 易于扩展的架构，企业可以在一个 FlexPod 平台上运行多个基因组工作负载，从而提高利用率并降低总拥有成本（ TCO ）。FlexPod 可以灵活地进行规模估算，从小型 FlexPod 快速计划开始，并可扩展到大型 FlexPod 数据中心实施。借助 Cisco Intersight 内置的基于角色的访问控制功能，医疗保健组织可以实施强大的访问控制机制，从而避免需要单独的基础架构堆栈。医疗保健组织内的多个业务部门可以将基因组作为一项关键核心能力。

  最终， FlexPod 有助于简化 IT 运营并降低运营成本， IT 基础架构管理员可以将精力集中在帮助临床医生创新的任务上，而不是仅仅为了让他们保持正常运行。

- 经过验证的设计和有保障的结果。 * FlexPod 设计和部署指南经过验证，可以重复使用，其中涵盖了放心部署 FlexPod 所需的全面配置详细信息和行业最佳实践。Cisco 和 NetApp 经验证的设计指南，部署指南和架构可帮助您的医疗保健或生命科学组织从一开始就消除实施经验证且值得信赖的平台时的猜测。借助 FlexPod ，您可以加快部署速度，降低成本，复杂性和风险。FlexPod 经验证的设计和部署指南将 FlexPod 确立为各种基因组工作负载的理想平台。
- * 创新与敏捷性。 * FlexPod 是 Epic ， Cerner ， Meditech 等 EHR 公司以及 Agfa ， GE ，飞利浦等成像系统的理想平台。有关的详细信息，请参见 "史诗般的荣誉卷" 和目标平台架构，请参见 Epic 用户 Web 。运行基因组学 "FlexPod" 让医疗保健组织能够灵活地继续其创新之旅。借助 FlexPod ，实施组织变革自然成为必然。当企业在 FlexPod 平台上实现标准化时，医疗保健 IT 专家可以为创新配置时间，精力和资源，从而实现生态系统所需的灵活性。
- * 数据解放。 * 借助 FlexPod 融合基础架构平台和 NetApp ONTAP 存储系统，可以通过一个平台上的各种规模协议提供和访问基因组数据。采用 NetApp ONTAP 的 FlexPod 提供了一个简单，直观且功能强大的混合云平台。由 NetApp ONTAP 提供支持的 Data Fabric 可跨站点，跨物理边界和跨应用程序将数据集于一体。您的 Data Fabric 专为以数据为中心的环境中的数据驱动型企业而构建。数据在多个位置创建和使用，通常

需要利用并与其他位置，应用程序和基础架构共享。因此，您需要采用一致且集成的方式来管理它。FlexPod 可以让您的 IT 团队掌控一切，并简化日益增加的 IT 复杂性。

- * 安全多租户。 * FlexPod 使用符合 FIPS 140-2 的加密模块，因此，企业可以将安全性作为基本要素来实施，而不是事后考虑。无论平台大小如何， FlexPod 都支持企业从一个融合基础架构平台实施安全多租户。采用安全多租户和 QoS 的 FlexPod 有助于分离工作负载并最大程度地提高利用率。这有助于避免资本被锁定到可能未充分利用且需要专业技能集进行管理的专用平台中。
- * 存储效率。 * 基因组学要求底层存储具有行业领先的存储效率功能。您可以利用 NetApp 存储效率功能降低存储成本，例如重复数据删除（实时和按需），数据压缩和数据缩减（ "ref"）。NetApp 重复数据删除可在 FlexVol 卷中提供块级重复数据删除。从本质上说，重复数据删除会删除重复的块，从而仅在 FlexVol 卷中存储唯一的块。重复数据删除的粒度较高，并在 FlexVol 卷的活动文件系统上运行。下图简要显示了 NetApp 重复数据删除的工作原理。重复数据删除是应用程序透明的。因此，可以使用它对使用 NetApp 系统的任何应用程序生成的数据进行重复数据删除。您可以将卷重复数据删除作为实时进程和后台进程运行。您可以将其配置为自动运行，计划运行或通过命令行界面， NetApp ONTAP System Manager 或 NetApp Active IQ Unified Manager 手动运行。

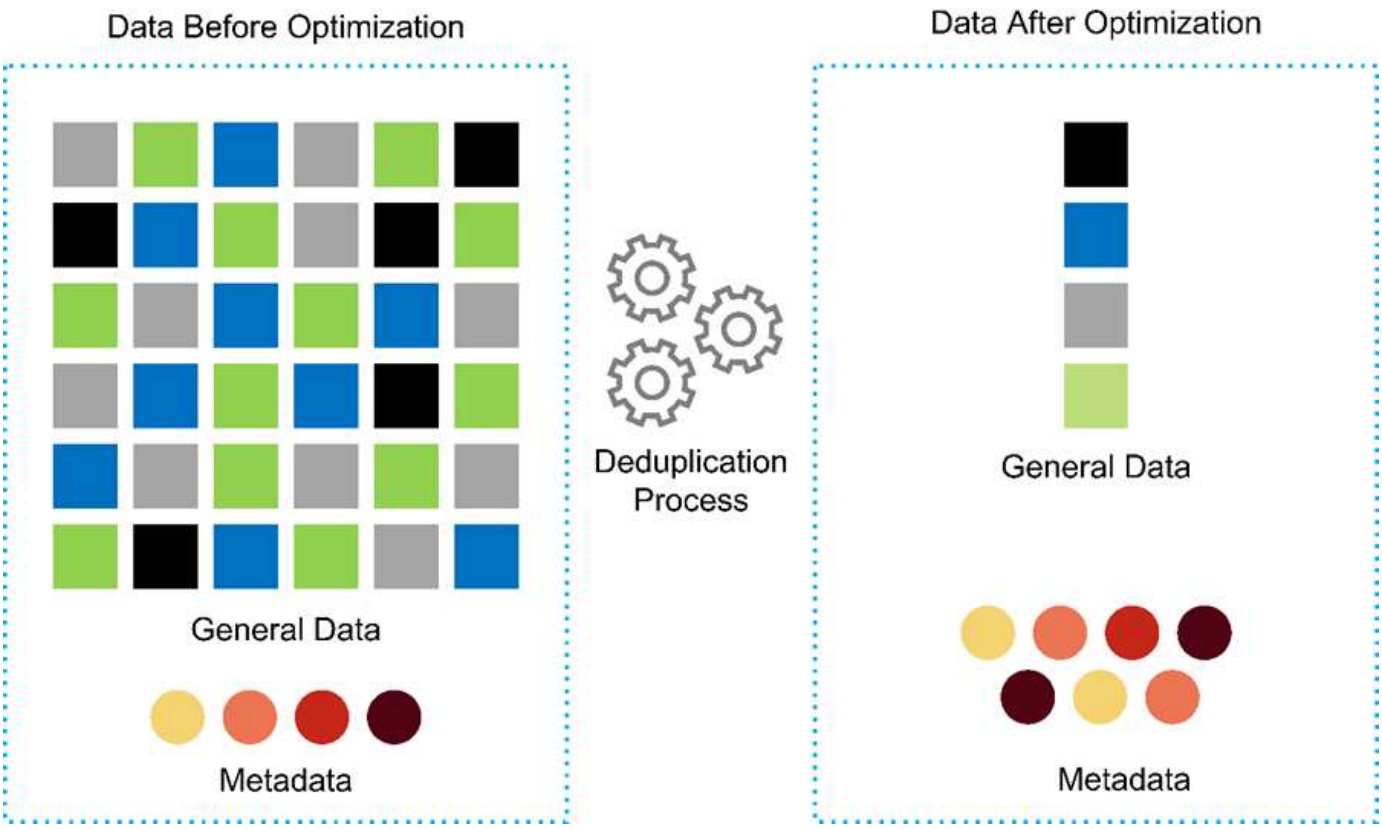

- * 实现基因组互操作性。 * ONTAP FlexCache 是一种远程缓存功能，可简化文件分发，减少 WAN 延迟并降低 WAN 带宽成本 "ref"）。基因组变体识别和标注期间的一项关键活动是临床医生之间的协作。即使协作临床医生位于不同地理位置， ONTAP FlexCache 技术也能提高数据吞吐量。鉴于 * 。 bam 文件的典型大小（ 1 GB 到 100 GB ），底层平台必须能够向不同地理位置的临床医生提供文件。采用 ONTAP FlexCache 的 FlexPod 让基因组数据和应用程序真正实现了多站点就绪，让全球各地的研究人员可以无缝协作，实现低延迟和高吞吐量。在多站点环境下运行基因组学应用程序的医疗保健组织可以使用数据网络结构进行横向扩展，以平衡易管理性与成本和速度。
- * 智能使用存储平台。 * 采用 ONTAP 自动分层和 NetApp Fabric Pool 技术的 FlexPod 可简化数据管理。FabricPool 有助于降低存储成本，而不会影响性能，效率，安全性或保护。FabricPool 对企业级应用程序是透明的，它可以降低存储 TCO ，而无需重新构建应用程序基础架构，从而充分利用云效率。FlexPod 可以从 FabricPool 的存储分层功能中受益，从而更高效地利用 ONTAP 闪存存储。有关详细信息，请参见 " 采用 FabricPool 的 FlexPod"。下图简要概述了 FabricPool 及其优势。

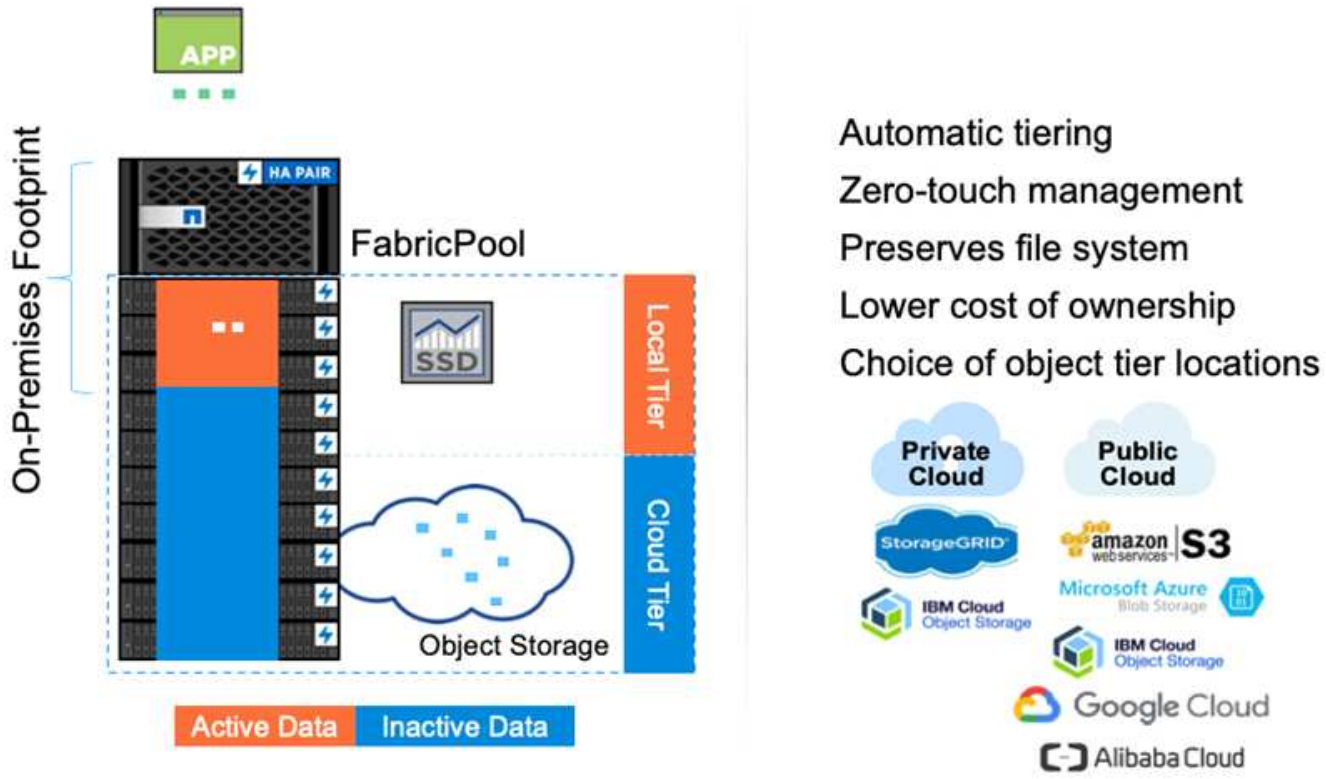

- * 更快的变体分析和标注速度。 * FlexPod 平台的部署和实施速度更快。FlexPod 平台可实现大规模数据可用，并提供低延迟和更高吞吐量，从而实现临床医生协作。增强的互操作性有助于创新。医疗保健组织可以并行运行基因组和非基因组工作负载，这意味着组织不需要专门的平台来开始其基因组学之旅。

  FlexPod ONTAP 会定期为存储平台添加前沿功能。FlexPod 数据中心是部署 FC-NVMe 以允许需要高性能存储访问的应用程序的最佳共享基础架构基础。随着 FC-NVMe 不断发展，包括高可用性，多路径和额外的操作系统支持， FlexPod 非常适合作为首选平台，可提供支持这些功能所需的可扩展性和可靠性。ONTAP 通过端到端 NVMe 实现更快的 I/O ，从而加快完成基因组分析的速度（ "ref"）。

  按顺序排列的原始基因组数据会产生较大的文件大小，因此，请务必将这些文件提供给变体分析器，以减少从样本收集到变体标注所需的总时间。NVMe （非易失性内存快速）用作存储访问和数据传输协议时，可提供前所未有的吞吐量水平和最快的响应时间。FlexPod 可在通过 PCI Express 总线（ PCIe ）访问闪存存储时部署 NVMe 协议。PCIe 支持实施数万个命令队列，从而提高了并行处理能力和吞吐量。从存储到内存的一个协议可以快速访问数据。

- * 从零到零的灵活性进行临床研究。 * 灵活，可扩展的存储容量和性能使医疗保健研究组织能够以弹性或实时（ JIT ）的方式优化环境。通过将存储与计算和网络基础架构分离，可以在不中断的情况下纵向和横向扩展 FlexPod 平台。使用 Cisco Intersight ，可以使用内置和自定义自动化工作流来管理 FlexPod 平台。借助 Cisco Intersight 工作流，医疗保健组织可以缩短应用程序生命周期管理时间。当学术医疗中心要求将患者数据匿名化并提供给其研究信息学中心和 / 或质量中心时，其 IT 组织可以利用 Cisco Intersight FlexPod 工作流在数秒内（而不是数小时）执行安全数据备份，克隆和还原。借助 NetApp Trident 和 Kubernetes ， IT 组织可以配置新的数据科学家，并在几分钟内（有时甚至几秒钟内）为模型开发提供临床数据。

- * 保护基因组数据。 * NetApp SnapLock 提供了一个专用卷，可在其中存储文件并将其置于不可擦除，不可重写的状态。用户驻留在 FlexVol 卷中的生产数据可以通过 NetApp SnapMirror 或 SnapVault 技术镜像或存储到 SnapLock 卷。在保留期限结束之前，无法删除 SnapLock 卷，卷本身及其托管聚合中的文件。使用 ONTAP FPolicy 软件，企业可以禁止对具有特定扩展名的文件执行操作，从而防止勒索软件攻击。可以为特定文件操作触发 FPolicy 事件。此事件与策略相关联，策略将调用需要使用的引擎。您可以为策略配置一组可能包含勒索软件的文件扩展名。如果具有不允许扩展名的文件尝试执行未经授权的操作，则 FPolicy 会阻

止执行该操作 ("ref"）。

- * FlexPod 合作支持。 * NetApp 和 Cisco 建立了 FlexPod 合作支持，这是一种强大，可扩展且灵活的支持模式，可满足 FlexPod 融合基础架构的独特支持要求。此模式结合了 NetApp 和 Cisco 的经验，资源和技术支持专业知识，可以简化识别和解决 FlexPod 支持问题的流程，而不管问题位于何处。下图概述了 FlexPod 合作支持模式。客户联系可能拥有问题描述的供应商， Cisco 和 NetApp 将合作解决此问题。Cisco 和 NetApp 拥有跨公司工程和开发团队，他们携手解决问题。此支持模式可减少翻译期间的信息丢失，建立信任并减少停机时间。

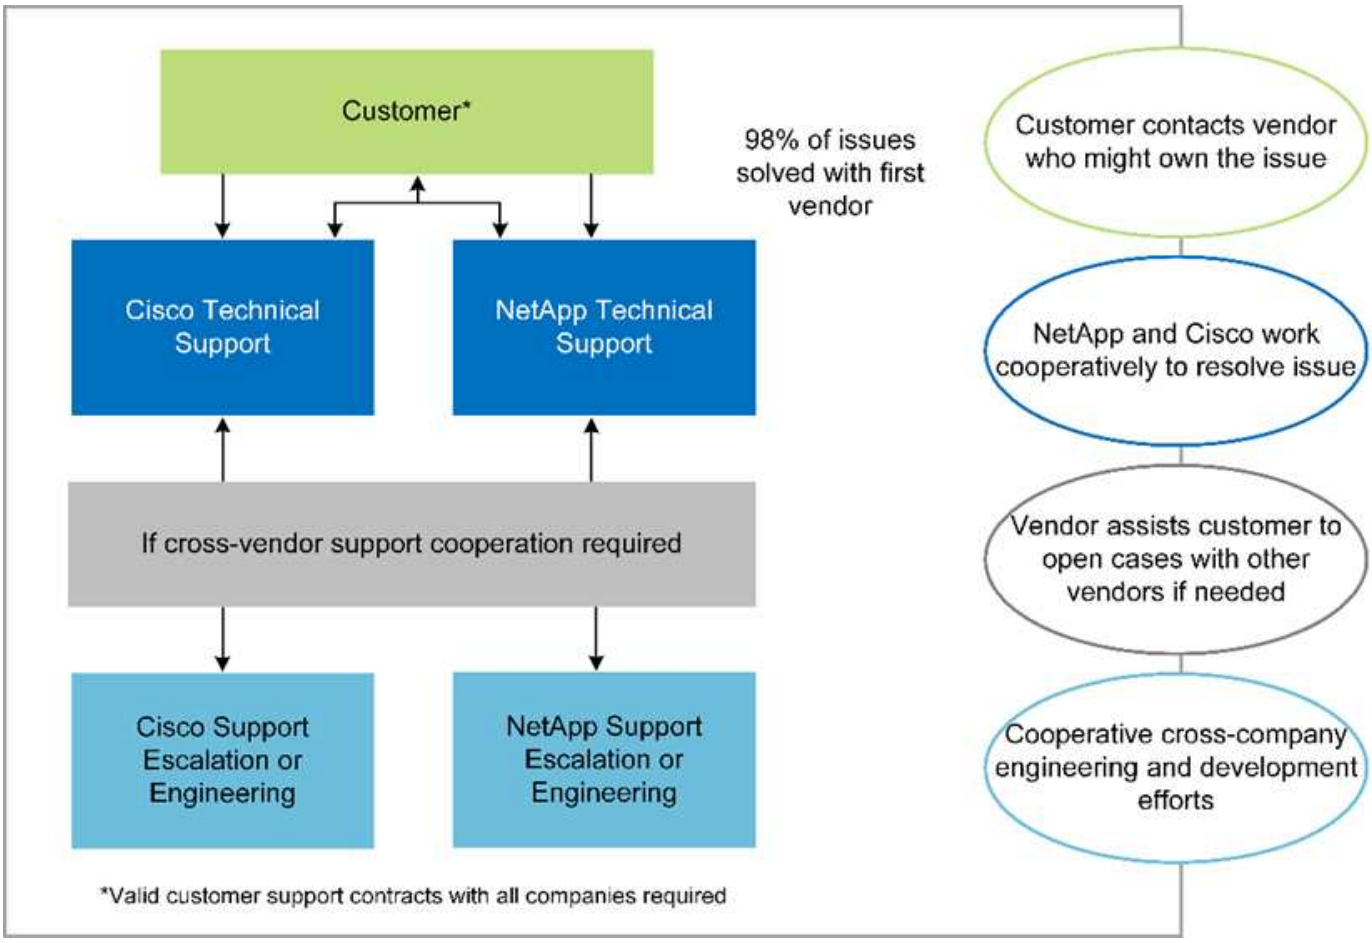

"接下来：解决方案基础架构硬件和软件组件。"

解决方案基础架构硬件和软件组件

"先前版本：在 FlexPod 上部署基因组工作负载的优势。"

下图显示了用于 GATK 设置和验证的 FlexPod 系统。我们使用了 "采用 VMware vSphere 7.0 和 NetApp ONTAP 9.7 的 FlexPod Datacenter Cisco 验证设计（ CVD ）" 在设置过程中。

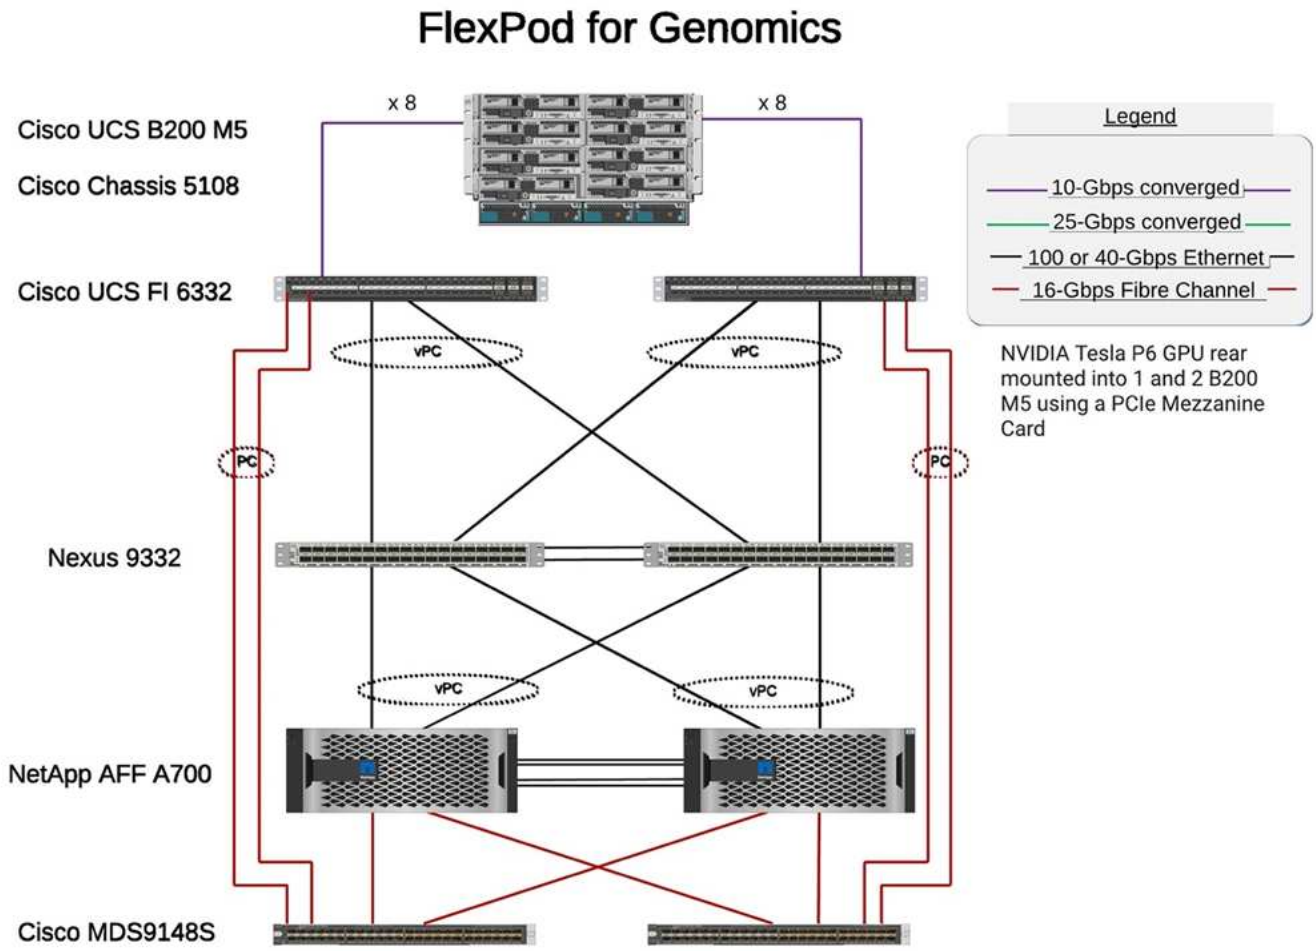

下图显示了 FlexPod 布线详细信息。

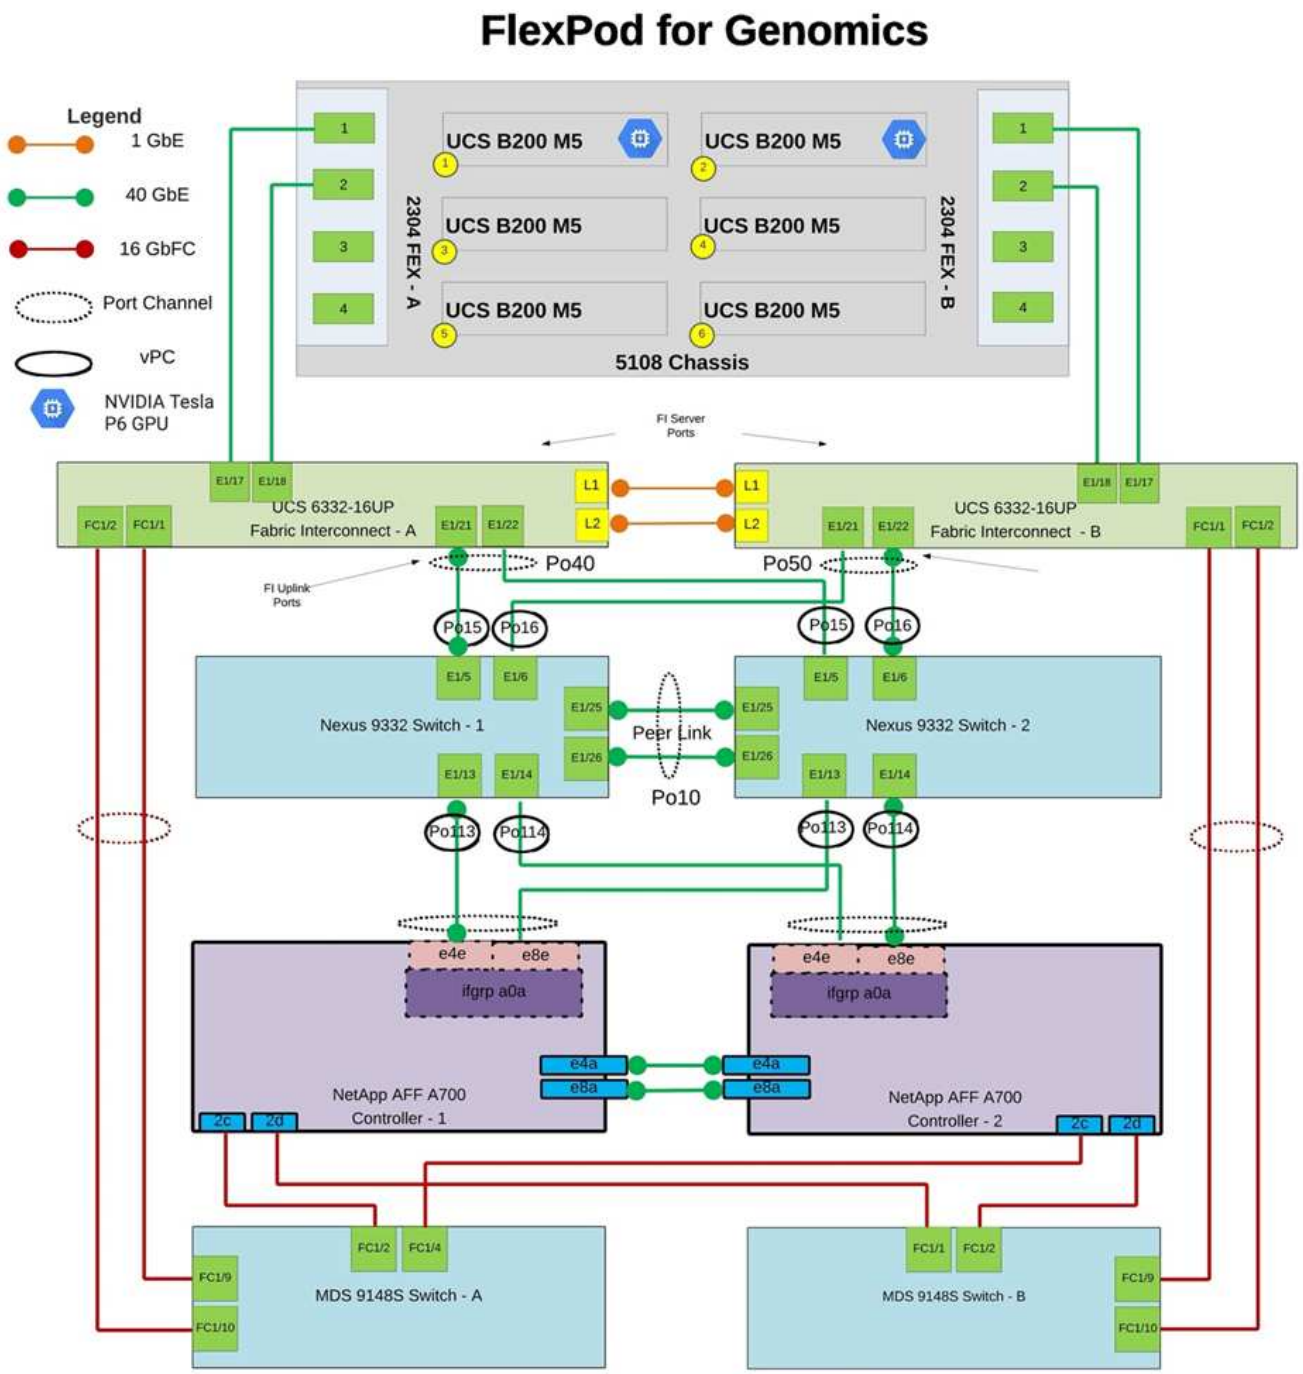

下表列出了在 FlexPod 上启用 GATK 测试期间使用的硬件组件。下面是 "NetApp 互操作性表工具" （IMT）和 "Cisco 硬件兼容性列表（HCL）"。

层	产品系列	数量和型号	详细信息
计算	Cisco UCS 5108 机箱	1 或 2	
	Cisco UCS 刀片式服务器	6 个 B200 M5	每个都具有 2 个 20 或更多核心， 2.7 GHz 和 128-384 GB RAM

层	产品系列	数量和型号	详细信息
	Cisco UCS 虚拟接口卡（VIC）	Cisco UCS 1440	请参见
	2 个 Cisco UCS 互联阵列	6332	-
网络	Cisco Nexus 交换机	2 个 Cisco Nexus 9332	-
存储网络	用于通过 SMB/CIFS，NFS 或 iSCSI 协议进行存储访问的 IP 网络	与上述相同的网络交换机	-
	通过 FC 进行存储访问	2 个 Cisco MDS 9148S	-
存储	NetApp AFF A700 全闪存存储系统	1 个集群	具有两个节点的集群
	磁盘架	一个 DS224C 或 NS224 磁盘架	已完全填充 24 个驱动器
	SSD	24， 1.2 TB 或更大容量	-

此表列出了基础架构软件。

软件	产品系列	版本或版本	详细信息
各种	Linux	RHEL 8.3	-
	Windows	Windows Server 2012 R2（64 位）	-
	NetApp ONTAP	ONTAP 9.8 或更高版本	-
	Cisco UCS 互联阵列	Cisco UCS Manager 4.1 或更高版本	-
	Cisco 以太网 3000 或 9000 系列交换机	对于 9000 系列，对于 3000 系列，则为 7.0 （3） i7 （7）或更高版本，对于 9.2 （4）或更高版本	-
	Cisco FC： Cisco MDS 9132T	8.4 （1a）或更高版本	-
	虚拟机管理程序	VMware vSphere ESXi 7.0	-
存储	虚拟机管理程序管理系统	VMware vCenter Server 7.0 （vCSA）或更高版本	-
网络	NetApp 虚拟存储控制台（VSC）	VSC 9.7 或更高版本	-
	NetApp SnapCenter	SnapCenter 4.3 或更高版本	-
	Cisco UCS Manager	4.1 （3c）或更高版本	
虚拟机管理程序	ESXi		

软件	产品系列	版本或版本	详细信息
管理	虚拟机管理程序管理系统 VMware vCenter Server 7.0 （ vCSA ）或更高版本		
	NetApp 虚拟存储控制台（ VSC ）	VSC 9.7 或更高版本	
	NetApp SnapCenter	SnapCenter 4.3 或更高版本	
	Cisco UCS Manager	4.1 （ 3c ）或更高版本	

"接下来：基因组学— GATK 设置和执行。"

基因组学— GATK 设置和执行

"先前版本：解决方案基础架构硬件和软件组件。"

根据国家人类基因组研究所（ "NHGRI"），" 基因组学是对一个人的所有基因（基因组）的研究，包括这些基因相互作用以及与人的环境相互作用。"

根据 "NHGRI"" 去氧碳核克利酸（ Deoxyribonucleic acid ， DNA/ 脱氧核素）是一种化合物，其中包含开发和指导几乎所有生物体活动所需的说明。DNA 分子由两个绞合成对的线组成，通常称为双螺旋。 " " 一个生物体的一整套基因称为其基因组。 "

测序是指确定基准在一个 DNA 链中的确切顺序的过程。当今最常见的排序类型之一称为 " 按合成排序 " 。此技术使用荧光信号的辐射来对基准进行排序。研究人员可以使用基因排序来搜索遗传变体以及在某个人仍处于萌芽阶段时可能对疾病的发展或发展起作用的任何变体。

从样本到变体标识，标注和预测

从较高的层面来看，基因组学可以分为以下几个步骤。以下列表并不详尽：

1. 样本收集。
2. "基因组测序" 使用序列发生器生成原始数据。
3. 预处理。例如： "deduplication" 使用 "图标"。
4. 基因组分析。
    a. 映射到参考基因组。
    b. "变体" 通常使用 GATK 和类似工具执行标识和标注。
5. 集成到电子运行状况记录（ EHR ）系统中。
6. "人口分层" 并确定跨地理位置和种族背景的遗传变体。
7. "预测模型" 使用显著的单核退潮多形态。
8. "验证"。

下图显示了从采样到变体标识，标注和预测的过程。

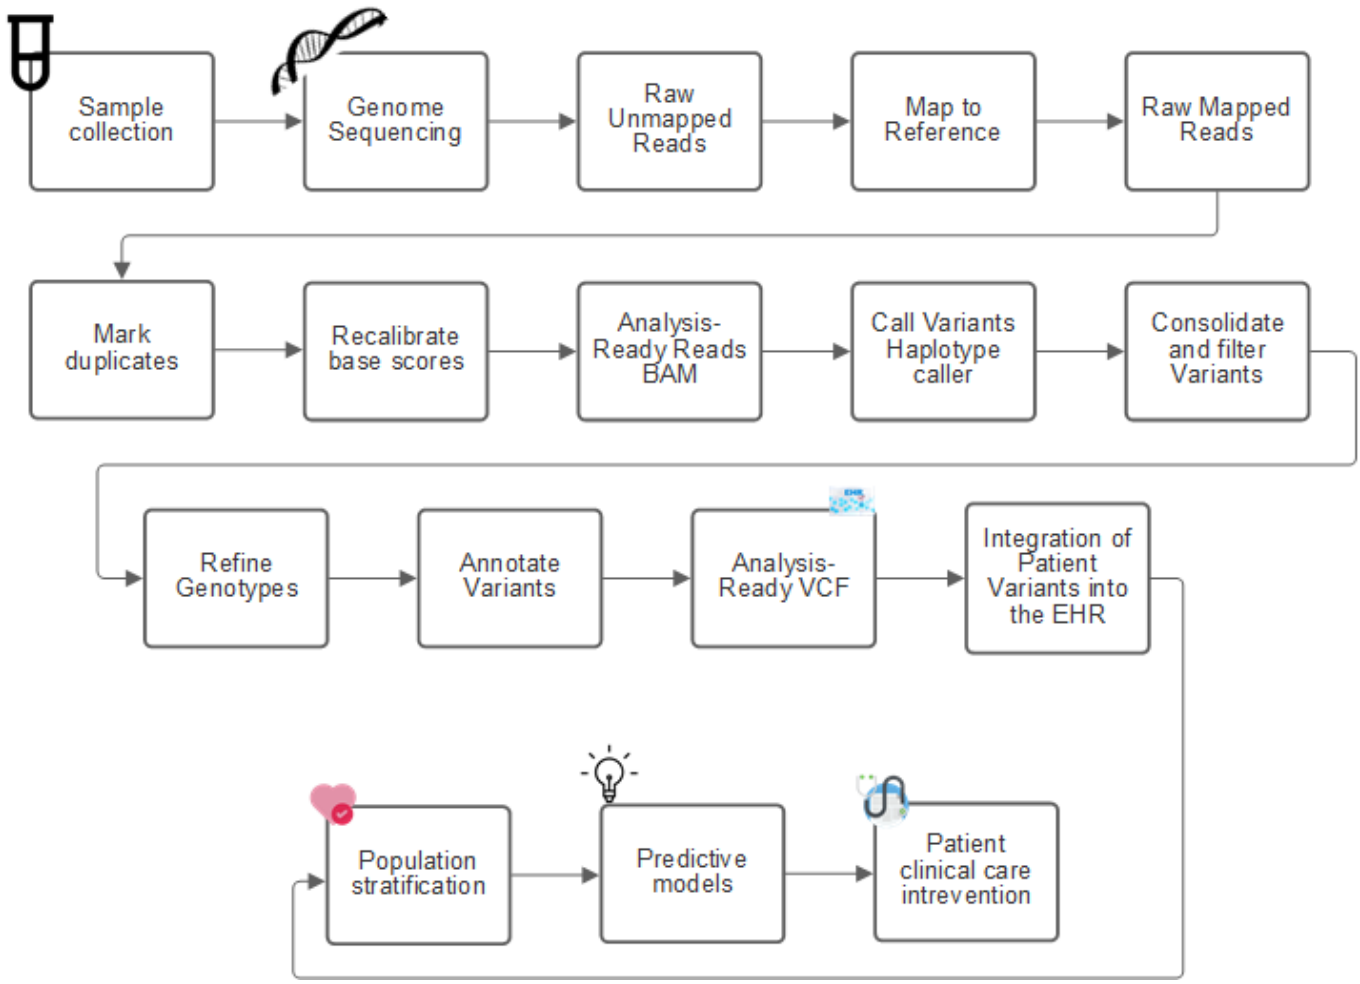

人类基因组项目于 2003 年 4 月完成，该项目对公有域中的人类基因组序列进行了高质量的模拟。这种参考基因组引发了基因组功能研究和开发的爆炸式增长。几乎每一种人类疾病都有其基因特征。直到最近，医生一直在利用基因预测和确定诸如镰状细胞性贫血之类的缺陷，这是由一个基因的变化所导致的某种继承模式引起的。人类基因组项目所提供的数据的宝贵财富导致了基因组功能的当前状态的出现。

基因组学具有一系列广泛的优势。以下是医疗保健和生命科学领域的一小部分优势：

- 更好地在护理点进行诊断
- 预后更好
- 精确医学
- 个性化的治疗计划
- 改善疾病监控
- 减少不利事件
- 改善获得治疗的途径
- 改进了疾病监控
- 有效地参与临床试验，并根据基因型更好地选择患者进行临床试验。

基因组学是一种 "四向 Beast ，" 因为数据集的整个生命周期都有计算需求：采集，存储，分布和分析。

基因组分析工具包（GATK）

GATK 是作为中的数据科学平台而开发的 "Broad Institute"。GATK 是一组开源工具，可用于进行基因组分析，尤其是变体发现，标识，标注和基因分型。GATK 的一个优势是，可以将一组工具和 / 或命令链接在一起，形成一个完整的工作流。广义学院要应对的主要挑战如下：

- 了解疾病的根本原因和生物机制。
- 确定可用于基本发生原因 of a disease 的治疗干预措施。
- 了解从各种变体到在人类物理中发挥作用的视觉特征。
- 制定标准和策略 "框架" 用于基因组数据表示，存储，分析，安全性等。
- 实现可互操作的基因组聚合数据库（gnomAD）的标准化和社交化。
- 基于基因组的患者监控，诊断和治疗更加精确。
- 帮助实施能够在症状出现之前很好地预测疾病的工具。
- 创建一个跨学科合作伙伴社区并赋予其能力，帮助解决生物医学领域最棘手，最重要的问题。

GATK 和 Broad Institute 表示，基因组测序应视为病理学实验室的一种协议；每个任务都经过了详细记录，优化，可重现，并在样本和实验中保持一致。下面是 Broad Institute 建议的一组步骤，有关详细信息，请参见 "GATK 网站"。

FlexPod 设置

基因组工作负载验证包括从头开始设置 FlexPod 基础架构平台。FlexPod 平台具有高可用性，可以独立扩展；例如，可以独立扩展网络，存储和计算。我们使用以下经过 Cisco 验证的设计指南作为参考架构文档来设置 FlexPod 环境： "采用 VMware vSphere 7.0 和 NetApp ONTAP 9.7 的 FlexPod Datacenter"。请参见以下 FlexPod 平台设置亮点：

要执行 FlexPod 实验室设置，请完成以下步骤：

1. FlexPod 实验室设置和验证使用以下 IP4 预留和 VLAN 。

IP Reservations

VLAN	IP Range	Subnet Mask	Purpose
3281	172.21.25 /24	255.255.255.0	IB-MGMT
3282	172.21.26 /24	255.255.255.0	vMotion
3283	172.21.27 /24	255.255.255.0	VM
3284	172.21.28 /24	255.255.255.0	NFS
3285	172.21.29 /24	255.255.255.0	iSCSI-A
3286	172.21.30 /24	255.255.255.0	iSCSI-B

2. 在 ONTAP SVM 上配置基于 iSCSI 的启动 LUN 。

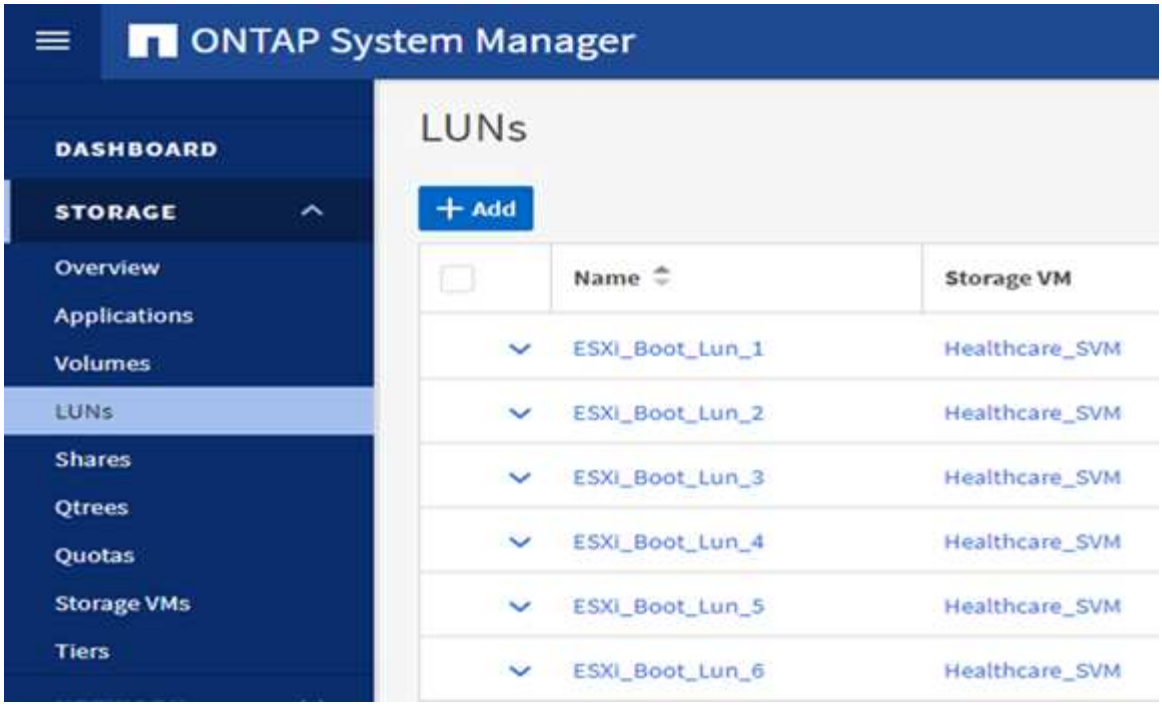

3. 将 LUN 映射到 iSCSI 启动程序组。

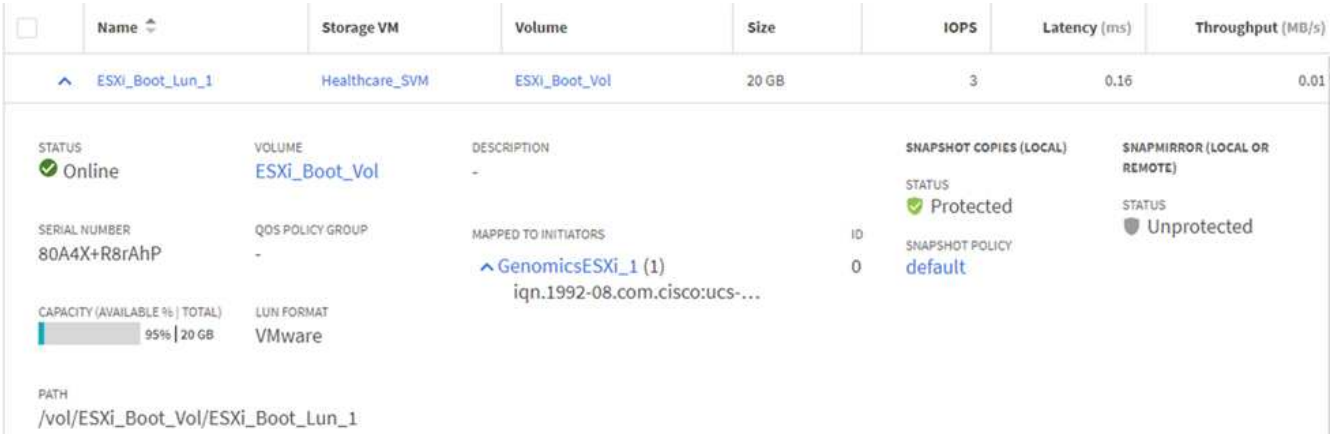

4. 使用 iSCSI 启动安装 vSphere 7.0 。
5. 向 vCenter 注册 ESXi 主机。

6. 在 ONTAP 存储上配置 NFS 数据存储库 `infra_datastore_nfs` 。

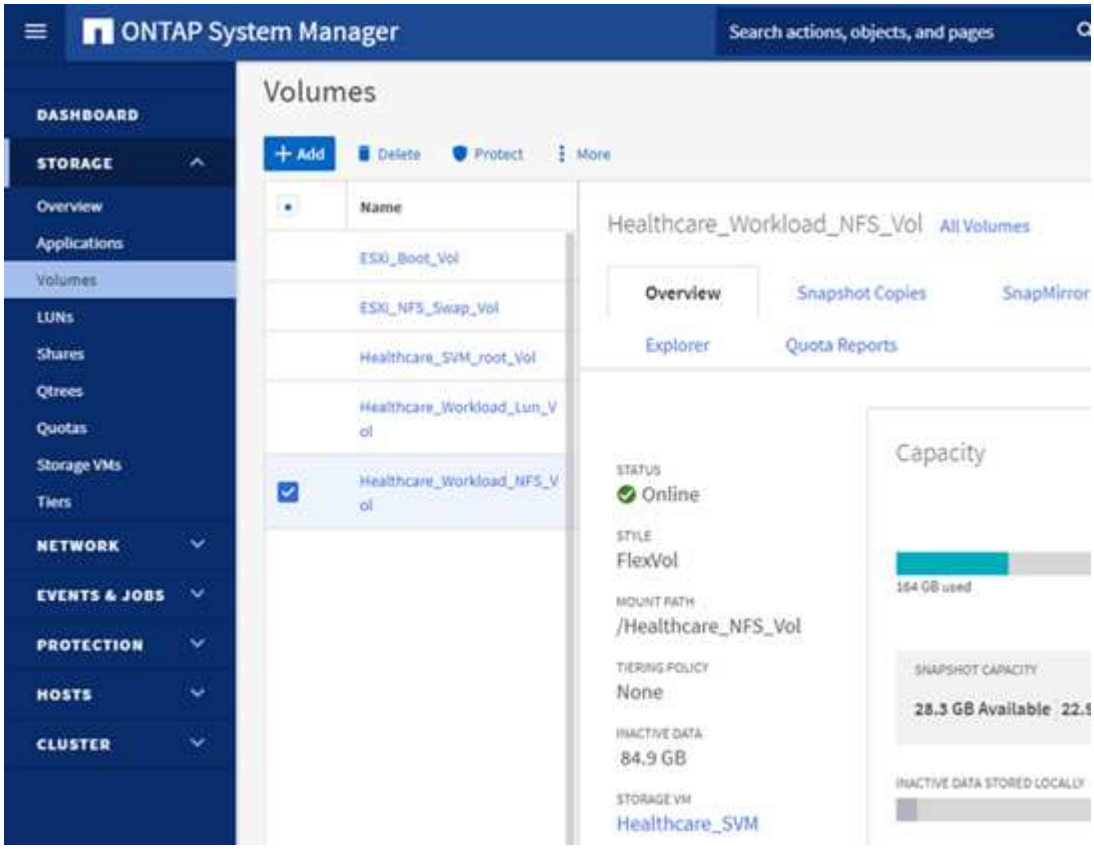

7. 将数据存储库添加到 vCenter 。

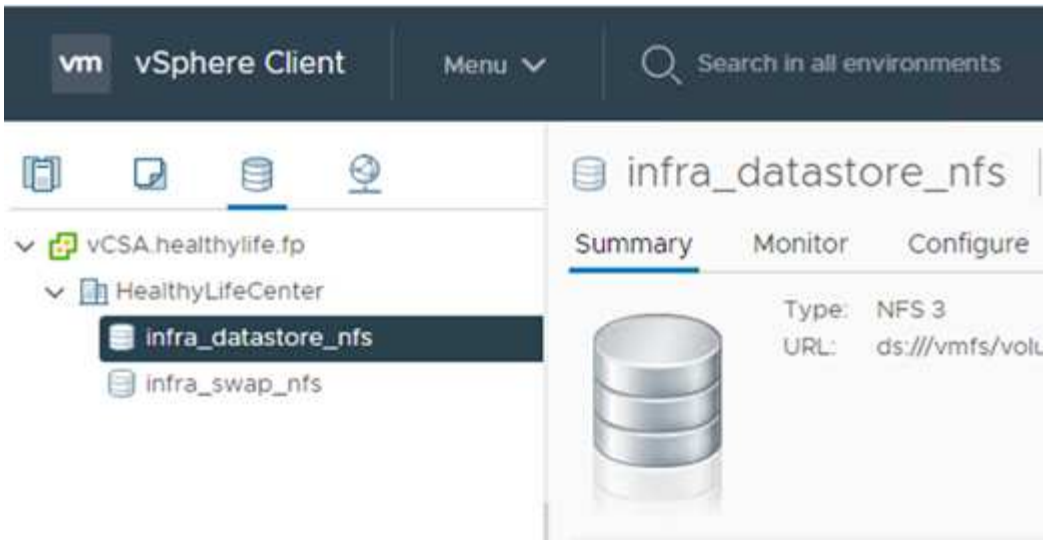

8. 使用 vCenter 向 ESXi 主机添加 NFS 数据存储库。

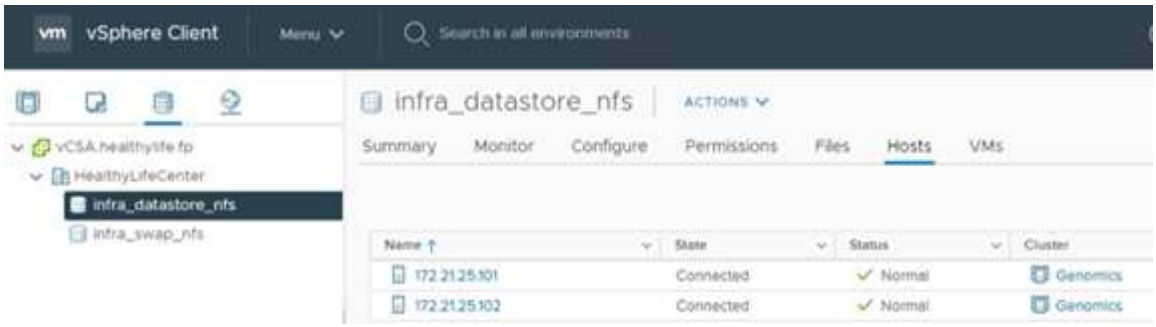

9. 使用 vCenter 创建 Red Hat Enterprise Linux （ RHEL ） 8.3 VM 以运行 GATK 。
10. NFS 数据存储库会提供给虚拟机并挂载在 ` /mnt/genomics` 中，用于存储 GATK 可执行文件，脚本，二进制对齐映射（ BAM ）文件，参考文件，索引文件，词典文件和输出文件，以用于变量调用。

```
[root@genomics1 genomics]# df | grep genomics
/dev/sdb                308587328  5699492 287142812   2% /mnt/genomics
[root@genomics1 genomics]#
```

GATK 设置和执行

在 RedHat Enterprise 8.3 Linux VM 上安装以下前提条件：

- Java 8 或 SDK 1.8 或更高版本
- 从 Broad Institute 下载 GATK 4.2.0.0 "GitHub 站点"。基因组序列数据通常以一系列制表符分隔的 ASCII 列的形式存储。但是， ASCII 需要的存储空间太多。因此，一个新标准会逐渐演变为 BAM （ * 。 bam ）文件。BAM 文件以压缩，索引和二进制形式存储序列数据。我们 "已下载" 一组公开可用的 BAM 文件，用于从执行 GATK "公有域"。我们还下载了索引文件（ * 。 bai ），词典文件（ * 。dict ）和引用数据文件（ * 。FASAA ）公有。

下载后， GATK 工具包将包含一个 JAR 文件和一组支持脚本。

- `gatk-package-4.2.0.0-local.jar` 可执行文件

- `gatk` 脚本文件。

我们下载了一个由父，母和子 * 。 bam 文件组成的系列的 BAM 文件以及相应的索引，词典和参考基因组文件。

克伦威尔引擎

Cromwell 是一款开源引擎，适用于支持工作流管理的科学工作流。可以将 Cromwell 引擎分为两种运行方式 "模式"，服务器模式或单工作流运行模式。可以使用控制 Cromwell 引擎的行为 "Cromwell 引擎配置文件"。

- * 服务器模式。 * 启用 "RESTful" 在 Cromwell 引擎中执行工作流。
- * 运行模式。 * 运行模式最适合在克伦威尔执行单个工作流， "ref" 查看运行模式下的一整套可用选项。

我们使用克伦威尔引擎大规模执行工作流和管道。Cromwell 引擎使用用户友好型 "Workflow 问题描述语言" （ WDL ）编写脚本的语言。此外，还支持第二个工作流脚本编写标准，称为通用工作流语言（ Common Workflow Language ， CWL ）。在本技术报告中，我们使用了 WDL 。WDL 最初是由广泛的基因组分析管道研究所开发的。使用 WDL 工作流可以通过多种策略来实施，其中包括：

- * 线性链。 * 顾名思义，任务 1 的输出将作为输入发送到任务 2 。
- * 多输入 / 输出。 * 这与线性链类似，因为每个任务都可以将多个输出作为输入发送到后续任务。
- * 散点收集。 * 这是最强大的企业应用程序集成（ EAI ）策略之一，尤其是在事件驱动型架构中使用时。每个任务以分离的方式执行，每个任务的输出将整合到最终输出中。

使用 WDL 在独立模式下运行 GATK 的步骤有三个：

1. 使用 `womtool.jar` 验证语法。

```
[root@genomics1 ~]#  java -jar womtool.jar validate ghplo.wdl
```

2. 生成输入 JSON 。

```
[root@genomics1 ~]#  java -jar womtool.jar inputs ghplo.wdl > ghplo.json
```

3. 使用 Cromwell 引擎和 `Cromwell.jar` 运行工作流。

```
[root@genomics1 ~]#  java -jar cromwell.jar run ghplo.wdl --inputs
ghplo.json
```

可以使用多种方法执行 GATK ；本文档将探讨其中三种方法。

使用 **JAR** 文件执行 **GATK**

下面我们来了解一下使用哈普斯特型变量调用程序执行单一变体调用管道的情况。

```
[root@genomics1 ~]#  java -Dsamjdk.use_async_io_read_samtools=false \
-Dsamjdk.use_async_io_write_samtools=true \
-Dsamjdk.use_async_io_write_tribble=false \
-Dsamjdk.compression_level=2 \
-jar /mnt/genomics/GATK/gatk-4.2.0.0/gatk-package-4.2.0.0-local.jar \
HaplotypeCaller \
--input /mnt/genomics/GATK/TEST\ DATA/bam/workshop_1906_2-
germline_bams_father.bam \
--output workshop_1906_2-germline_bams_father.validation.vcf \
--reference /mnt/genomics/GATK/TEST\ DATA/ref/workshop_1906_2-
germline_ref_ref.fasta
```

在这种执行方法中，我们使用 GATK 本地执行 JAR 文件，使用一个 Java 命令调用该 JAR 文件，并将多个参数传递到该命令。

1. 此参数表示我们正在调用 `Hplotypecaller` 变量调用程序管道。
2. ` - 输入` 指定输入 BAM 文件。
3. ` -output` 以变体调用格式（ * 。 vcf ）指定变体输出文件 ("ref"）。
4. 使用 ` -reference` 参数时，我们将传递一个参考基因组。

执行后，可以在部分中找到输出详细信息 "使用 JAR 文件执行 GATK 的输出。"

使用 **./gatk** 脚本执行 **GATK**

GATK 工具套件可使用 ` 。 /gatk` 脚本执行。让我们来看看以下命令：

```
[root@genomics1 execution]# ./gatk \
--java-options "-Xmx4G" \
HaplotypeCaller \
-I /mnt/genomics/GATK/TEST\ DATA/bam/workshop_1906_2-
germline_bams_father.bam \
-R /mnt/genomics/GATK/TEST\ DATA/ref/workshop_1906_2-
germline_ref_ref.fasta \
-O /mnt/genomics/GATK/TEST\ DATA/variants.vcf
```

我们会向命令传递多个参数。

- 此参数表示我们正在调用 `Hplotypecaller` 变量调用程序管道。
- ` -i` 指定输入 BAM 文件。
- ` -O` 以变体调用格式（ * 。 vcf ）指定变体输出文件 ("ref"）。
- 使用 ` -R` 参数时，我们会传递一个参考基因组。

执行后，可以在部分中找到输出详细信息 "使用 ` 。 /gatk` 脚本执行 GATK 的输出。"

使用 **Cromwell** 引擎执行 **GATK**

我们使用 Cromwell 引擎管理 GATK 执行。我们来检查命令行及其参数。

```
[root@genomics1 genomics]# java -jar cromwell-65.jar \
run /mnt/genomics/GATK/seq/ghplo.wdl  \
--inputs /mnt/genomics/GATK/seq/ghplo.json
```

在此，我们通过传递 `-JAR` 参数来调用 Java 命令，以指示我们要执行 JAR 文件，例如， `Cromwell-65.jar` 。传递的下一个参数（`run` ）表示 Cromwell 引擎正在运行模式，另一个可能的选项是服务器模式。下一个参数为 `* 。 wdll` ，运行模式应使用该参数执行管道。下一个参数是要执行的工作流的一组输入参数。

以下是 `ghplo.wdll` 文件的内容：

```
[root@genomics1 seq]# cat ghplo.wdl
workflow helloHaplotypeCaller {
  call haplotypeCaller
}
task haplotypeCaller {
  File GATK
  File RefFasta
  File RefIndex
  File RefDict
  String sampleName
  File inputBAM
  File bamIndex
  command {
    java -jar ${GATK} \
         HaplotypeCaller \
        -R ${RefFasta} \
        -I ${inputBAM} \
        -O ${sampleName}.raw.indels.snps.vcf
  }
  output {
    File rawVCF = "${sampleName}.raw.indels.snps.vcf"
  }
}
[root@genomics1 seq]#
```

下面是相应的 JSON 文件以及对 Cromwell 引擎的输入。

```
[root@genomics1 seq]# cat ghplo.json
{
"helloHaplotypeCaller.haplotypeCaller.GATK": "/mnt/genomics/GATK/gatk-
4.2.0.0/gatk-package-4.2.0.0-local.jar",
"helloHaplotypeCaller.haplotypeCaller.RefFasta": "/mnt/genomics/GATK/TEST
DATA/ref/workshop_1906_2-germline_ref_ref.fasta",
"helloHaplotypeCaller.haplotypeCaller.RefIndex": "/mnt/genomics/GATK/TEST
DATA/ref/workshop_1906_2-germline_ref_ref.fasta.fai",
"helloHaplotypeCaller.haplotypeCaller.RefDict": "/mnt/genomics/GATK/TEST
DATA/ref/workshop_1906_2-germline_ref_ref.dict",
"helloHaplotypeCaller.haplotypeCaller.sampleName": "fatherbam",
"helloHaplotypeCaller.haplotypeCaller.inputBAM": "/mnt/genomics/GATK/TEST
DATA/bam/workshop_1906_2-germline_bams_father.bam",
"helloHaplotypeCaller.haplotypeCaller.bamIndex": "/mnt/genomics/GATK/TEST
DATA/bam/workshop_1906_2-germline_bams_father.bai"
}
[root@genomics1 seq]#
```

请注意， Cromwell 使用内存数据库来执行。执行后，输出日志将显示在一节中 "使用 Cromwell 引擎执行 GATK 的输出。"

有关如何执行 GATK 的一组完整步骤，请参见 "GATK 文档"。

"下一步：使用 JAR 文件执行 GATK 的输出。"

使用 JAR 文件执行 GATK 的输出

"上一篇：基因组学— GATK 设置和执行。"

使用 Jar 文件执行 GATK 会生成以下示例输出。

```
[root@genomics1 execution]# java -Dsamjdk.use_async_io_read_samtools=false
\
-Dsamjdk.use_async_io_write_samtools=true \
-Dsamjdk.use_async_io_write_tribble=false \
-Dsamjdk.compression_level=2 \
-jar /mnt/genomics/GATK/gatk-4.2.0.0/gatk-package-4.2.0.0-local.jar \
HaplotypeCaller \
--input /mnt/genomics/GATK/TEST\ DATA/bam/workshop_1906_2-
germline_bams_father.bam \
--output workshop_1906_2-germline_bams_father.validation.vcf \
--reference /mnt/genomics/GATK/TEST\ DATA/ref/workshop_1906_2-
germline_ref_ref.fasta \
22:52:58.430 INFO  NativeLibraryLoader - Loading libgkl_compression.so
from jar:file:/mnt/genomics/GATK/gatk-4.2.0.0/gatk-package-4.2.0.0-
```

```
local.jar!/com/intel/gkl/native/libgkl_compression.so
Aug 17, 2021 10:52:58 PM
shaded.cloud_nio.com.google.auth.oauth2.ComputeEngineCredentials
runningOnComputeEngine
INFO: Failed to detect whether we are running on Google Compute Engine.
22:52:58.541 INFO  HaplotypeCaller -
------------------------------------------------------------
22:52:58.542 INFO  HaplotypeCaller - The Genome Analysis Toolkit (GATK)
v4.2.0.0
22:52:58.542 INFO  HaplotypeCaller - For support and documentation go to
https://software.broadinstitute.org/gatk/
22:52:58.542 INFO  HaplotypeCaller - Executing as
root@genomics1.healthylife.fp on Linux v4.18.0-305.3.1.el8_4.x86_64 amd64
22:52:58.542 INFO  HaplotypeCaller - Java runtime: OpenJDK 64-Bit Server
VM v1.8.0_302-b08
22:52:58.542 INFO  HaplotypeCaller - Start Date/Time: August 17, 2021
10:52:58 PM EDT
22:52:58.542 INFO  HaplotypeCaller -
------------------------------------------------------------
22:52:58.542 INFO  HaplotypeCaller -
------------------------------------------------------------
22:52:58.542 INFO  HaplotypeCaller - HTSJDK Version: 2.24.0
22:52:58.542 INFO  HaplotypeCaller - Picard Version: 2.25.0
22:52:58.542 INFO  HaplotypeCaller - Built for Spark Version: 2.4.5
22:52:58.542 INFO  HaplotypeCaller - HTSJDK Defaults.COMPRESSION_LEVEL : 2
22:52:58.543 INFO  HaplotypeCaller - HTSJDK
Defaults.USE_ASYNC_IO_READ_FOR_SAMTOOLS : false
22:52:58.543 INFO  HaplotypeCaller - HTSJDK
Defaults.USE_ASYNC_IO_WRITE_FOR_SAMTOOLS : true
22:52:58.543 INFO  HaplotypeCaller - HTSJDK
Defaults.USE_ASYNC_IO_WRITE_FOR_TRIBBLE : false
22:52:58.543 INFO  HaplotypeCaller - Deflater: IntelDeflater
22:52:58.543 INFO  HaplotypeCaller - Inflater: IntelInflater
22:52:58.543 INFO  HaplotypeCaller - GCS max retries/reopens: 20
22:52:58.543 INFO  HaplotypeCaller - Requester pays: disabled
22:52:58.543 INFO  HaplotypeCaller - Initializing engine
22:52:58.804 INFO  HaplotypeCaller - Done initializing engine
22:52:58.809 INFO  HaplotypeCallerEngine - Disabling physical phasing,
which is supported only for reference-model confidence output
22:52:58.820 INFO  NativeLibraryLoader - Loading libgkl_utils.so from
jar:file:/mnt/genomics/GATK/gatk-4.2.0.0/gatk-package-4.2.0.0-
local.jar!/com/intel/gkl/native/libgkl_utils.so
22:52:58.821 INFO  NativeLibraryLoader - Loading libgkl_pairhmm_omp.so
from jar:file:/mnt/genomics/GATK/gatk-4.2.0.0/gatk-package-4.2.0.0-
local.jar!/com/intel/gkl/native/libgkl_pairhmm_omp.so
22:52:58.854 INFO  IntelPairHmm - Using CPU-supported AVX-512 instructions
```

```
22:52:58.854 INFO  IntelPairHmm - Flush-to-zero (FTZ) is enabled when
running PairHMM
22:52:58.854 INFO  IntelPairHmm - Available threads: 16
22:52:58.854 INFO  IntelPairHmm - Requested threads: 4
22:52:58.854 INFO  PairHMM - Using the OpenMP multi-threaded AVX-
accelerated native PairHMM implementation
22:52:58.872 INFO  ProgressMeter - Starting traversal
22:52:58.873 INFO  ProgressMeter -        Current Locus  Elapsed Minutes
Regions Processed   Regions/Minute
22:53:00.733 WARN  InbreedingCoeff - InbreedingCoeff will not be
calculated at position 20:9999900 and possibly subsequent; at least 10
samples must have called genotypes
22:53:08.873 INFO  ProgressMeter -          20:17538652              0.2
58900         353400.0
22:53:17.681 INFO  HaplotypeCaller - 405 read(s) filtered by:
MappingQualityReadFilter
0 read(s) filtered by: MappingQualityAvailableReadFilter
0 read(s) filtered by: MappedReadFilter
0 read(s) filtered by: NotSecondaryAlignmentReadFilter
6628 read(s) filtered by: NotDuplicateReadFilter
0 read(s) filtered by: PassesVendorQualityCheckReadFilter
0 read(s) filtered by: NonZeroReferenceLengthAlignmentReadFilter
0 read(s) filtered by: GoodCigarReadFilter
0 read(s) filtered by: WellformedReadFilter
7033 total reads filtered
22:53:17.681 INFO  ProgressMeter -          20:63024652              0.3
210522         671592.9
22:53:17.681 INFO  ProgressMeter - Traversal complete. Processed 210522
total regions in 0.3 minutes.
22:53:17.687 INFO  VectorLoglessPairHMM - Time spent in setup for JNI call
: 0.010347438
22:53:17.687 INFO  PairHMM - Total compute time in PairHMM
computeLogLikelihoods() : 0.259172573
22:53:17.687 INFO  SmithWatermanAligner - Total compute time in java
Smith-Waterman : 1.27 sec
22:53:17.687 INFO  HaplotypeCaller - Shutting down engine
[August 17, 2021 10:53:17 PM EDT]
org.broadinstitute.hellbender.tools.walkers.haplotypecaller.HaplotypeCalle
r done. Elapsed time: 0.32 minutes.
Runtime.totalMemory()=5561122816
[root@genomics1 execution]#
```

请注意，输出文件位于执行后指定的位置。

"Next： 使用 ` ./gatk` 脚本执行 GATK 的输出。"

使用 ./gatk 脚本执行 GATK 的输出

"previous： 使用 JAR 文件执行 GATK 的输出。"

使用 `。 /gatk` 脚本执行 GATK 后，生成了以下示例输出。

```
[root@genomics1 gatk-4.2.0.0]# ./gatk --java-options "-Xmx4G" \
HaplotypeCaller \
-I /mnt/genomics/GATK/TEST\ DATA/bam/workshop_1906_2-
germline_bams_father.bam \
-R /mnt/genomics/GATK/TEST\ DATA/ref/workshop_1906_2-
germline_ref_ref.fasta \
-O /mnt/genomics/GATK/TEST\ DATA/variants.vcf
Using GATK jar /mnt/genomics/GATK/gatk-4.2.0.0/gatk-package-4.2.0.0-
local.jar
Running:
    java -Dsamjdk.use_async_io_read_samtools=false
-Dsamjdk.use_async_io_write_samtools=true
-Dsamjdk.use_async_io_write_tribble=false -Dsamjdk.compression_level=2
-Xmx4G -jar /mnt/genomics/GATK/gatk-4.2.0.0/gatk-package-4.2.0.0-local.jar
HaplotypeCaller -I /mnt/genomics/GATK/TEST DATA/bam/workshop_1906_2-
germline_bams_father.bam -R /mnt/genomics/GATK/TEST
DATA/ref/workshop_1906_2-germline_ref_ref.fasta -O /mnt/genomics/GATK/TEST
DATA/variants.vcf
23:29:45.553 INFO  NativeLibraryLoader - Loading libgkl_compression.so
from jar:file:/mnt/genomics/GATK/gatk-4.2.0.0/gatk-package-4.2.0.0-
local.jar!/com/intel/gkl/native/libgkl_compression.so
Aug 17, 2021 11:29:45 PM
shaded.cloud_nio.com.google.auth.oauth2.ComputeEngineCredentials
runningOnComputeEngine
INFO: Failed to detect whether we are running on Google Compute Engine.
23:29:45.686 INFO  HaplotypeCaller -
------------------------------------------------------------
23:29:45.686 INFO  HaplotypeCaller - The Genome Analysis Toolkit (GATK)
v4.2.0.0
23:29:45.686 INFO  HaplotypeCaller - For support and documentation go to
https://software.broadinstitute.org/gatk/
23:29:45.687 INFO  HaplotypeCaller - Executing as
root@genomics1.healthylife.fp on Linux v4.18.0-305.3.1.el8_4.x86_64 amd64
23:29:45.687 INFO  HaplotypeCaller - Java runtime: OpenJDK 64-Bit Server
VM v11.0.12+7-LTS
23:29:45.687 INFO  HaplotypeCaller - Start Date/Time: August 17, 2021 at
11:29:45 PM EDT
23:29:45.687 INFO  HaplotypeCaller -
------------------------------------------------------------
23:29:45.687 INFO  HaplotypeCaller -
```

```
------------------------------------------------------------
23:29:45.687 INFO  HaplotypeCaller - HTSJDK Version: 2.24.0
23:29:45.687 INFO  HaplotypeCaller - Picard Version: 2.25.0
23:29:45.687 INFO  HaplotypeCaller - Built for Spark Version: 2.4.5
23:29:45.688 INFO  HaplotypeCaller - HTSJDK Defaults.COMPRESSION_LEVEL : 2
23:29:45.688 INFO  HaplotypeCaller - HTSJDK
Defaults.USE_ASYNC_IO_READ_FOR_SAMTOOLS : false
23:29:45.688 INFO  HaplotypeCaller - HTSJDK
Defaults.USE_ASYNC_IO_WRITE_FOR_SAMTOOLS : true
23:29:45.688 INFO  HaplotypeCaller - HTSJDK
Defaults.USE_ASYNC_IO_WRITE_FOR_TRIBBLE : false
23:29:45.688 INFO  HaplotypeCaller - Deflater: IntelDeflater
23:29:45.688 INFO  HaplotypeCaller - Inflater: IntelInflater
23:29:45.688 INFO  HaplotypeCaller - GCS max retries/reopens: 20
23:29:45.688 INFO  HaplotypeCaller - Requester pays: disabled
23:29:45.688 INFO  HaplotypeCaller - Initializing engine
23:29:45.804 INFO  HaplotypeCaller - Done initializing engine
23:29:45.809 INFO  HaplotypeCallerEngine - Disabling physical phasing,
which is supported only for reference-model confidence output
23:29:45.818 INFO  NativeLibraryLoader - Loading libgkl_utils.so from
jar:file:/mnt/genomics/GATK/gatk-4.2.0.0/gatk-package-4.2.0.0-
local.jar!/com/intel/gkl/native/libgkl_utils.so
23:29:45.819 INFO  NativeLibraryLoader - Loading libgkl_pairhmm_omp.so
from jar:file:/mnt/genomics/GATK/gatk-4.2.0.0/gatk-package-4.2.0.0-
local.jar!/com/intel/gkl/native/libgkl_pairhmm_omp.so
23:29:45.852 INFO  IntelPairHmm - Using CPU-supported AVX-512 instructions
23:29:45.852 INFO  IntelPairHmm - Flush-to-zero (FTZ) is enabled when
running PairHMM
23:29:45.852 INFO  IntelPairHmm - Available threads: 16
23:29:45.852 INFO  IntelPairHmm - Requested threads: 4
23:29:45.852 INFO  PairHMM - Using the OpenMP multi-threaded AVX-
accelerated native PairHMM implementation
23:29:45.868 INFO  ProgressMeter - Starting traversal
23:29:45.868 INFO  ProgressMeter -        Current Locus  Elapsed Minutes
Regions Processed   Regions/Minute
23:29:47.772 WARN  InbreedingCoeff - InbreedingCoeff will not be
calculated at position 20:9999900 and possibly subsequent; at least 10
samples must have called genotypes
23:29:55.868 INFO  ProgressMeter -          20:18885652              0.2
63390         380340.0
23:30:04.389 INFO  HaplotypeCaller - 405 read(s) filtered by:
MappingQualityReadFilter
0 read(s) filtered by: MappingQualityAvailableReadFilter
0 read(s) filtered by: MappedReadFilter
0 read(s) filtered by: NotSecondaryAlignmentReadFilter
6628 read(s) filtered by: NotDuplicateReadFilter
```

```
0 read(s) filtered by: PassesVendorQualityCheckReadFilter
0 read(s) filtered by: NonZeroReferenceLengthAlignmentReadFilter
0 read(s) filtered by: GoodCigarReadFilter
0 read(s) filtered by: WellformedReadFilter
7033 total reads filtered
23:30:04.389 INFO  ProgressMeter -          20:63024652              0.3
210522         681999.9
23:30:04.389 INFO  ProgressMeter - Traversal complete. Processed 210522
total regions in 0.3 minutes.
23:30:04.395 INFO  VectorLoglessPairHMM - Time spent in setup for JNI call
: 0.012129203000000002
23:30:04.395 INFO  PairHMM - Total compute time in PairHMM
computeLogLikelihoods() : 0.267345217
23:30:04.395 INFO  SmithWatermanAligner - Total compute time in java
Smith-Waterman : 1.23 sec
23:30:04.395 INFO  HaplotypeCaller - Shutting down engine
[August 17, 2021 at 11:30:04 PM EDT]
org.broadinstitute.hellbender.tools.walkers.haplotypecaller.HaplotypeCalle
r done. Elapsed time: 0.31 minutes.
Runtime.totalMemory()=2111832064
[root@genomics1 gatk-4.2.0.0]#
```

请注意，输出文件位于执行后指定的位置。

"下一步：使用 Cromwell 引擎执行 GATK 的输出。"

使用 Cromwell 引擎执行 GATK 的输出

"previous： 使用 ` ./gatk` 脚本执行 GATK 的输出。"

使用 Cromwell 引擎执行 GATK 后，生成了以下示例输出。

```
[root@genomics1 genomics]# java -jar  cromwell-65.jar run
/mnt/genomics/GATK/seq/ghplo.wdl  --inputs
/mnt/genomics/GATK/seq/ghplo.json
[2021-08-18 17:10:50,78] [info] Running with database db.url =
jdbc:hsqldb:mem:856a1f0d-9a0d-42e5-9199-
5e6c1d0f72dd;shutdown=false;hsqldb.tx=mvcc
[2021-08-18 17:10:57,74] [info] Running migration
RenameWorkflowOptionsInMetadata with a read batch size of 100000 and a
write batch size of 100000
[2021-08-18 17:10:57,75] [info] [RenameWorkflowOptionsInMetadata] 100%
[2021-08-18 17:10:57,83] [info] Running with database db.url =
jdbc:hsqldb:mem:6afe0252-2dc9-4e57-8674-
ce63c67aa142;shutdown=false;hsqldb.tx=mvcc
[2021-08-18 17:10:58,17] [info] Slf4jLogger started
```

```
[2021-08-18 17:10:58,33] [info] Workflow heartbeat configuration:
{
  "cromwellId" : "cromid-41b7e30",
  "heartbeatInterval" : "2 minutes",
  "ttl" : "10 minutes",
  "failureShutdownDuration" : "5 minutes",
  "writeBatchSize" : 10000,
  "writeThreshold" : 10000
}
[2021-08-18 17:10:58,38] [info] Metadata summary refreshing every 1
second.
[2021-08-18 17:10:58,38] [info] No metadata archiver defined in config
[2021-08-18 17:10:58,38] [info] No metadata deleter defined in config
[2021-08-18 17:10:58,40] [info] KvWriteActor configured to flush with
batch size 200 and process rate 5 seconds.
[2021-08-18 17:10:58,40] [info] WriteMetadataActor configured to flush
with batch size 200 and process rate 5 seconds.
[2021-08-18 17:10:58,44] [info] CallCacheWriteActor configured to flush
with batch size 100 and process rate 3 seconds.
[2021-08-18 17:10:58,44] [warn] 'docker.hash-lookup.gcr-api-queries-per-
100-seconds' is being deprecated, use 'docker.hash-lookup.gcr.throttle'
instead (see reference.conf)
[2021-08-18 17:10:58,54] [info] JobExecutionTokenDispenser - Distribution
rate: 50 per 1 seconds.
[2021-08-18 17:10:58,58] [info] SingleWorkflowRunnerActor: Version 65
[2021-08-18 17:10:58,58] [info] SingleWorkflowRunnerActor: Submitting
workflow
[2021-08-18 17:10:58,64] [info] Unspecified type (Unspecified version)
workflow 3e246147-b1a9-41dc-8679-319f81b7701e submitted
[2021-08-18 17:10:58,66] [info] SingleWorkflowRunnerActor: Workflow
submitted 3e246147-b1a9-41dc-8679-319f81b7701e
[2021-08-18 17:10:58,66] [info] 1 new workflows fetched by cromid-41b7e30:
3e246147-b1a9-41dc-8679-319f81b7701e
[2021-08-18 17:10:58,67] [info] WorkflowManagerActor: Starting workflow
3e246147-b1a9-41dc-8679-319f81b7701e
[2021-08-18 17:10:58,68] [info] WorkflowManagerActor: Successfully started
WorkflowActor-3e246147-b1a9-41dc-8679-319f81b7701e
[2021-08-18 17:10:58,68] [info] Retrieved 1 workflows from the
WorkflowStoreActor
[2021-08-18 17:10:58,70] [info] WorkflowStoreHeartbeatWriteActor
configured to flush with batch size 10000 and process rate 2 minutes.
[2021-08-18 17:10:58,76] [info] MaterializeWorkflowDescriptorActor
[3e246147]: Parsing workflow as WDL draft-2
[2021-08-18 17:10:59,34] [info] MaterializeWorkflowDescriptorActor
[3e246147]: Call-to-Backend assignments:
helloHaplotypeCaller.haplotypeCaller -> Local
```

```
[2021-08-18 17:11:00,54] [info] WorkflowExecutionActor-3e246147-b1a9-41dc-
8679-319f81b7701e [3e246147]: Starting
helloHaplotypeCaller.haplotypeCaller
[2021-08-18 17:11:01,56] [info] Assigned new job execution tokens to the
following groups: 3e246147: 1
[2021-08-18 17:11:01,70] [info] BackgroundConfigAsyncJobExecutionActor
[3e246147helloHaplotypeCaller.haplotypeCaller:NA:1]: java -jar
/mnt/genomics/cromwell-executions/helloHaplotypeCaller/3e246147-b1a9-41dc-
8679-319f81b7701e/call-haplotypeCaller/inputs/-179397211/gatk-package-
4.2.0.0-local.jar \
     HaplotypeCaller \
    -R /mnt/genomics/cromwell-executions/helloHaplotypeCaller/3e246147-
b1a9-41dc-8679-319f81b7701e/call-
haplotypeCaller/inputs/604632695/workshop_1906_2-germline_ref_ref.fasta \
    -I /mnt/genomics/cromwell-executions/helloHaplotypeCaller/3e246147-
b1a9-41dc-8679-319f81b7701e/call-
haplotypeCaller/inputs/604617202/workshop_1906_2-germline_bams_father.bam
\
    -O fatherbam.raw.indels.snps.vcf
[2021-08-18 17:11:01,72] [info] BackgroundConfigAsyncJobExecutionActor
[3e246147helloHaplotypeCaller.haplotypeCaller:NA:1]: executing: /bin/bash
/mnt/genomics/cromwell-executions/helloHaplotypeCaller/3e246147-b1a9-41dc-
8679-319f81b7701e/call-haplotypeCaller/execution/script
[2021-08-18 17:11:03,49] [info] BackgroundConfigAsyncJobExecutionActor
[3e246147helloHaplotypeCaller.haplotypeCaller:NA:1]: job id: 26867
[2021-08-18 17:11:03,53] [info] BackgroundConfigAsyncJobExecutionActor
[3e246147helloHaplotypeCaller.haplotypeCaller:NA:1]: Status change from -
to WaitingForReturnCode
[2021-08-18 17:11:03,54] [info] Not triggering log of token queue status.
Effective log interval = None
[2021-08-18 17:11:23,65] [info] BackgroundConfigAsyncJobExecutionActor
[3e246147helloHaplotypeCaller.haplotypeCaller:NA:1]: Status change from
WaitingForReturnCode to Done
[2021-08-18 17:11:25,04] [info] WorkflowExecutionActor-3e246147-b1a9-41dc-
8679-319f81b7701e [3e246147]: Workflow helloHaplotypeCaller complete.
Final Outputs:
{
  "helloHaplotypeCaller.haplotypeCaller.rawVCF": "/mnt/genomics/cromwell-
executions/helloHaplotypeCaller/3e246147-b1a9-41dc-8679-319f81b7701e/call-
haplotypeCaller/execution/fatherbam.raw.indels.snps.vcf"
}
[2021-08-18 17:11:28,43] [info] WorkflowManagerActor: Workflow actor for
3e246147-b1a9-41dc-8679-319f81b7701e completed with status 'Succeeded'.
The workflow will be removed from the workflow store.
[2021-08-18 17:11:32,24] [info] SingleWorkflowRunnerActor workflow
finished with status 'Succeeded'.
```

```
{
  "outputs": {
    "helloHaplotypeCaller.haplotypeCaller.rawVCF":
"/mnt/genomics/cromwell-executions/helloHaplotypeCaller/3e246147-b1a9-
41dc-8679-319f81b7701e/call-
haplotypeCaller/execution/fatherbam.raw.indels.snps.vcf"
  },
  "id": "3e246147-b1a9-41dc-8679-319f81b7701e"
}
[2021-08-18 17:11:33,45] [info] Workflow polling stopped
[2021-08-18 17:11:33,46] [info] 0 workflows released by cromid-41b7e30
[2021-08-18 17:11:33,46] [info] Shutting down WorkflowStoreActor - Timeout
= 5 seconds
[2021-08-18 17:11:33,46] [info] Shutting down WorkflowLogCopyRouter -
Timeout = 5 seconds
[2021-08-18 17:11:33,46] [info] Shutting down JobExecutionTokenDispenser -
Timeout = 5 seconds
[2021-08-18 17:11:33,46] [info] Aborting all running workflows.
[2021-08-18 17:11:33,46] [info] JobExecutionTokenDispenser stopped
[2021-08-18 17:11:33,46] [info] WorkflowStoreActor stopped
[2021-08-18 17:11:33,47] [info] WorkflowLogCopyRouter stopped
[2021-08-18 17:11:33,47] [info] Shutting down WorkflowManagerActor -
Timeout = 3600 seconds
[2021-08-18 17:11:33,47] [info] WorkflowManagerActor: All workflows
finished
[2021-08-18 17:11:33,47] [info] WorkflowManagerActor stopped
[2021-08-18 17:11:33,64] [info] Connection pools shut down
[2021-08-18 17:11:33,64] [info] Shutting down SubWorkflowStoreActor -
Timeout = 1800 seconds
[2021-08-18 17:11:33,64] [info] Shutting down JobStoreActor - Timeout =
1800 seconds
[2021-08-18 17:11:33,64] [info] Shutting down CallCacheWriteActor -
Timeout = 1800 seconds
[2021-08-18 17:11:33,64] [info] SubWorkflowStoreActor stopped
[2021-08-18 17:11:33,64] [info] Shutting down ServiceRegistryActor -
Timeout = 1800 seconds
[2021-08-18 17:11:33,64] [info] Shutting down DockerHashActor - Timeout =
1800 seconds
[2021-08-18 17:11:33,64] [info] Shutting down IoProxy - Timeout = 1800
seconds
[2021-08-18 17:11:33,64] [info] CallCacheWriteActor Shutting down: 0
queued messages to process
[2021-08-18 17:11:33,64] [info] JobStoreActor stopped
[2021-08-18 17:11:33,64] [info] CallCacheWriteActor stopped
[2021-08-18 17:11:33,64] [info] KvWriteActor Shutting down: 0 queued
messages to process
```

```
[2021-08-18 17:11:33,64] [info] IoProxy stopped
[2021-08-18 17:11:33,64] [info] WriteMetadataActor Shutting down: 0 queued
messages to process
[2021-08-18 17:11:33,65] [info] ServiceRegistryActor stopped
[2021-08-18 17:11:33,65] [info] DockerHashActor stopped
[2021-08-18 17:11:33,67] [info] Database closed
[2021-08-18 17:11:33,67] [info] Stream materializer shut down
[2021-08-18 17:11:33,67] [info] WDL HTTP import resolver closed
[root@genomics1 genomics]#
```

"下一步： GPU 设置。"

GPU 设置

"previous ： 使用 Cromwell 引擎执行 GATK 的输出。"

截至发布时， GATK 工具不支持在内部执行基于 GPU 的原生。我们提供了以下设置和指导，帮助读者了解使用 GATK PCIe 夹层卡在后部安装的 NVIDIA Tesla P6 GPU 上使用 FlexPod 的简单程度。

我们使用以下 Cisco 验证设计（ Cisco Validated Design ， CVD ）作为参考架构和最佳实践指南来设置 FlexPod 环境，以便可以运行使用 GPU 的应用程序。

- "适用于 AI/ML 的 FlexPod 数据中心与适用于深度学习的 Cisco UCS 480 ML"

下面是此设置期间的一组要点：

1. 我们在 UCS B200 M5 服务器的夹层插槽中使用了 PCIe NVIDIA Tesla P6 GPU 。

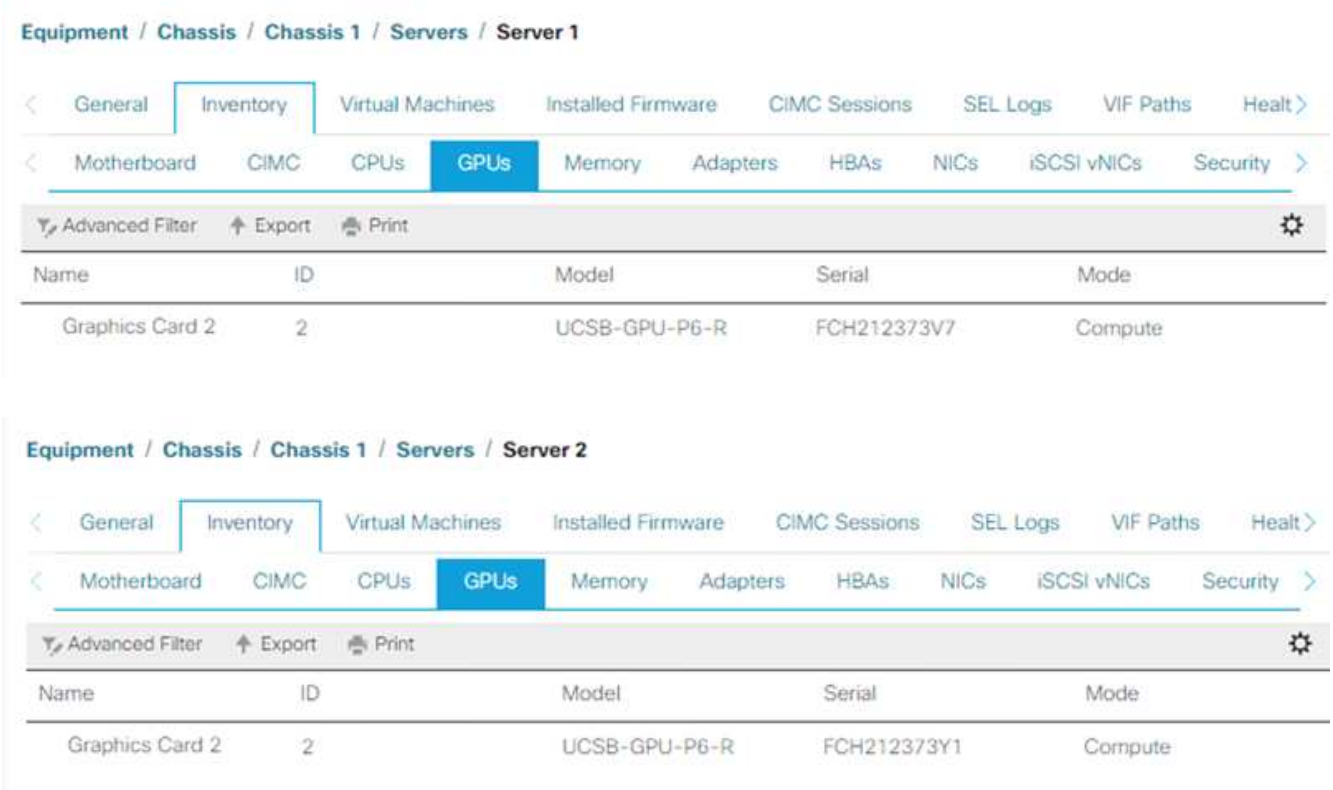

2. 对于此设置，我们已在 NVIDIA 合作伙伴门户上注册，并获得了一个评估许可证（也称为授权），以便能够在计算模式下使用 GPU 。
3. 我们从 NVIDIA 合作伙伴网站下载了所需的 NVIDIA vGPU 软件。
4. 我们从 NVIDIA 合作伙伴网站下载了授权 ` * 。 bin` 文件。
5. 我们安装了一个 NVIDIA vGPU 许可证服务器，并使用从 NVIDIA 合作伙伴站点下载的 ` * 。 bin` 文件将授权添加到许可证服务器。
6. 确保在 NVIDIA 合作伙伴门户上为您的部署选择正确的 NVIDIA vGPU 软件版本。在此设置中，我们使用的驱动程序版本为 460.73.02 。
7. 此命令将安装 "NVIDIA vGPU Manager" 在 ESXi 中。

```
[root@localhost:~] esxcli software vib install -v
/vmfs/volumes/infra_datastore_nfs/nvidia/vib/NVIDIA_bootbank_NVIDIA-
VMware_ESXi_7.0_Host_Driver_460.73.02-1OEM.700.0.0.15525992.vib
Installation Result
Message: Operation finished successfully.
Reboot Required: false
VIBs Installed: NVIDIA_bootbank_NVIDIA-
VMware_ESXi_7.0_Host_Driver_460.73.02-1OEM.700.0.0.15525992
VIBs Removed:
VIBs Skipped:
```

8. 重新启动 ESXi 服务器后，运行以下命令以验证 GPU 的安装并检查其运行状况。

```
[root@localhost:~] nvidia-smi
Wed Aug 18 21:37:19 2021
+-----------------------------------------------------------------------------
------+
| NVIDIA-SMI 460.73.02    Driver Version: 460.73.02    CUDA Version: N/A
|
|-------------------------------+----------------------
+----------------------+
| GPU  Name        Persistence-M| Bus-Id        Disp.A | Volatile
Uncorr. ECC |
| Fan  Temp  Perf  Pwr:Usage/Cap|         Memory-Usage | GPU-Util
Compute M. |
|                               |                      |
MIG M. |
|===============================+======================+================
======|
|   0  Tesla P6            On   | 00000000:D8:00.0 Off |
0 |
| N/A   35C    P8     9W /  90W |  15208MiB / 15359MiB |      0%
Default |
|                               |                      |
N/A |
+-------------------------------+----------------------
+----------------------+
+-----------------------------------------------------------------------------
------+
| Processes:
|
|  GPU   GI   CI        PID   Type   Process name                  GPU
Memory |
|        ID   ID                                                   Usage
|
|=============================================================================
======|
|    0   N/A  N/A   2812553    C+G   RHEL01
15168MiB |
+-----------------------------------------------------------------------------
------+
[root@localhost:~]
```

9. 使用 vCenter， "配置" 图形设备设置为 "shared direction" 。

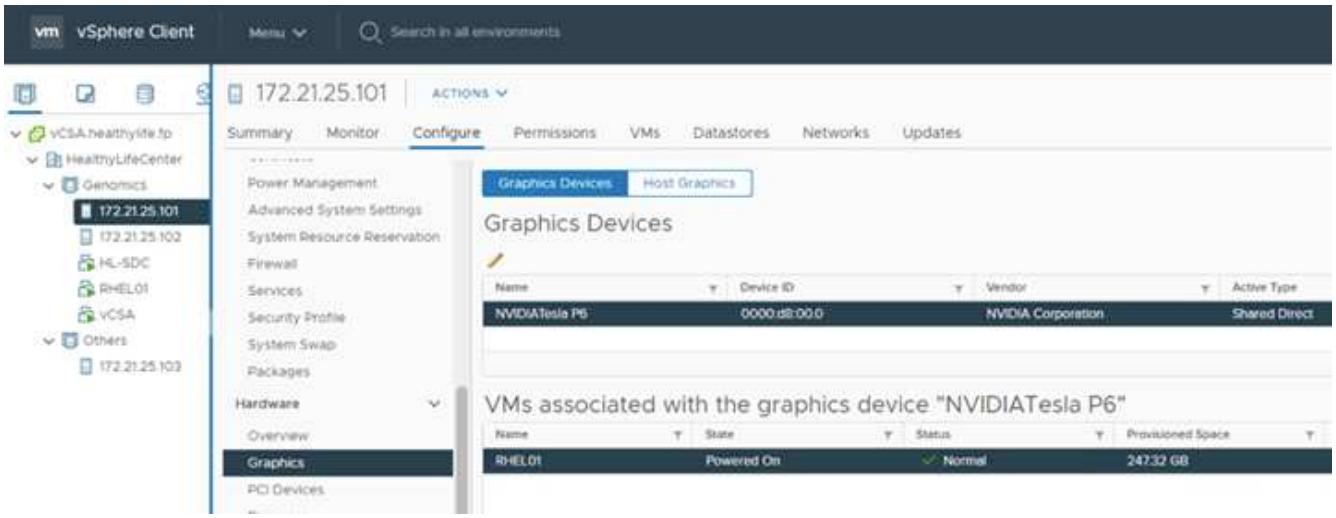

10. 确保已为 RedHat VM 禁用安全启动。
11. 确保 VM 启动选项固件设置为 EFI （"ref"）。

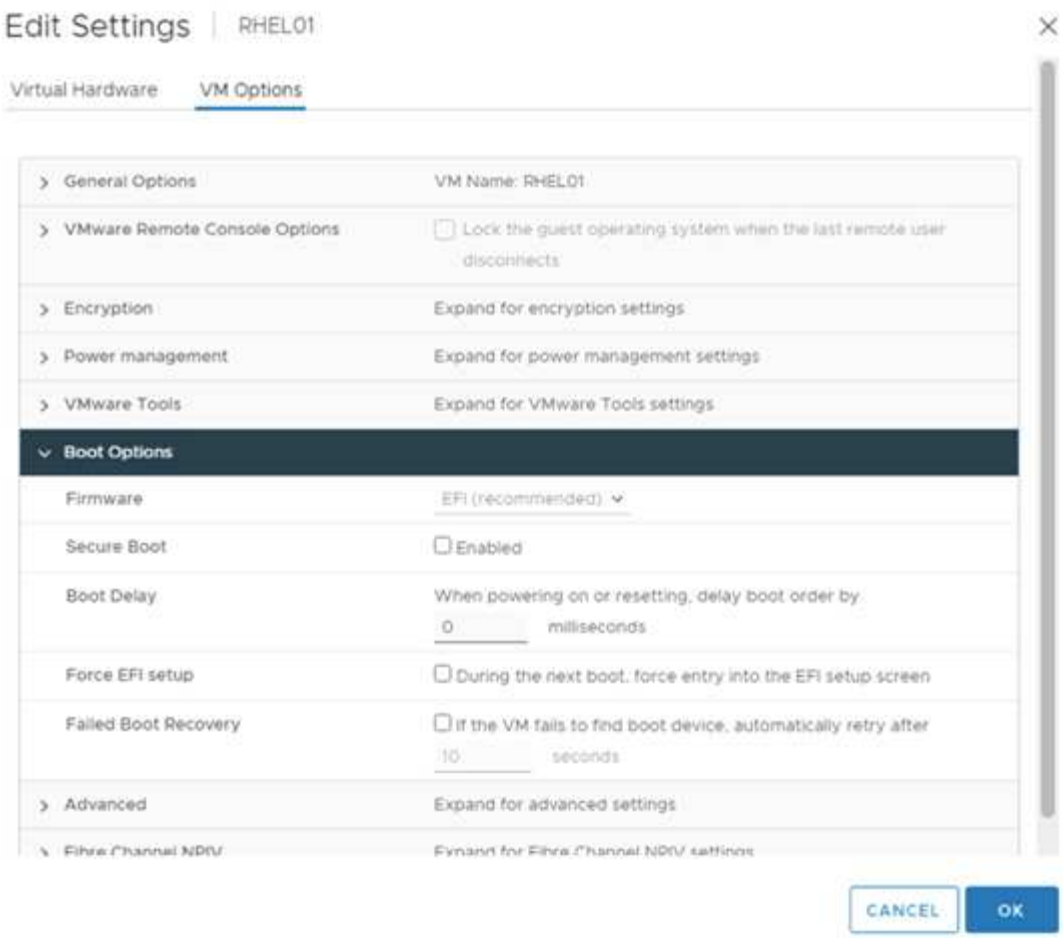

12. 确保已将以下参数添加到 VM 选项高级编辑配置中。`pciPassthru .64bitMMIOSizeGB` 参数的值取决于 GPU 内存和分配给虚拟机的 GPU 数量。例如：

    a. 如果为虚拟机分配了 4 个 32 GB V100 GPU ，则此值应为 128 。

    b. 如果为虚拟机分配了 4 个 16 GB P6 GPU ，则此值应为 64 。

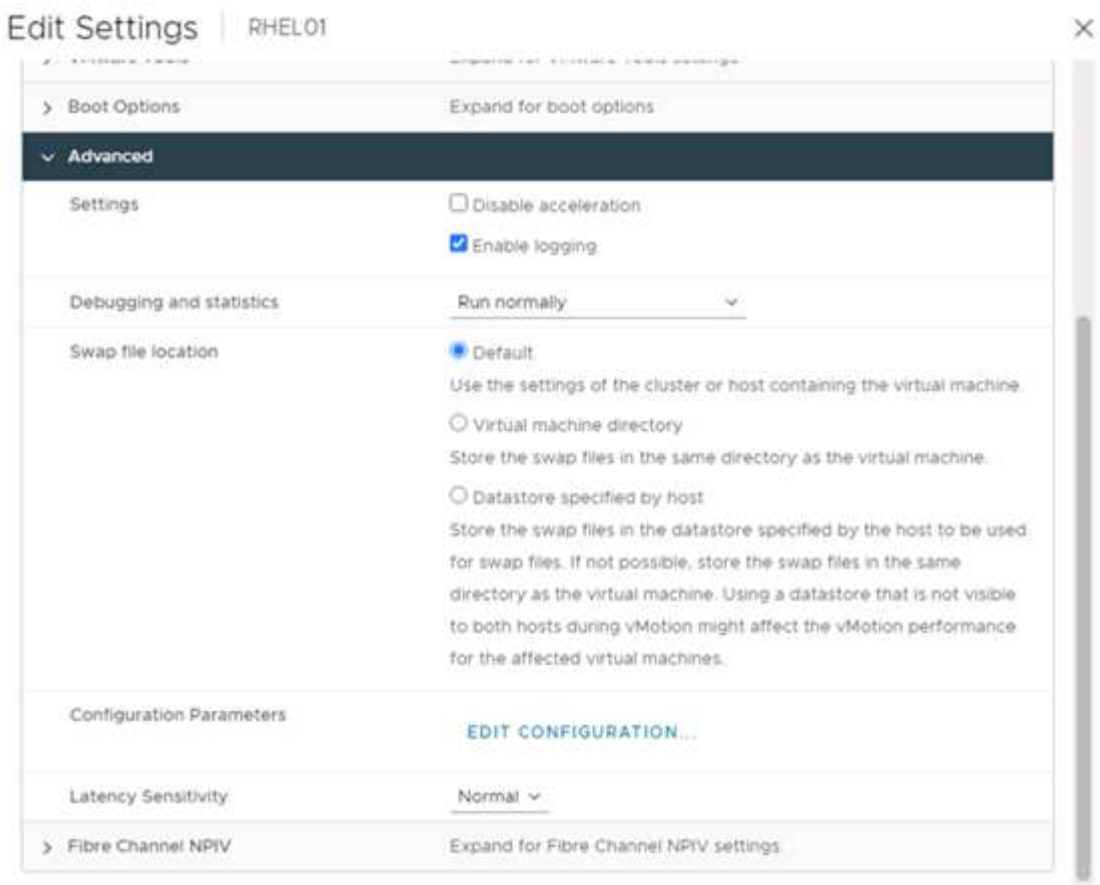

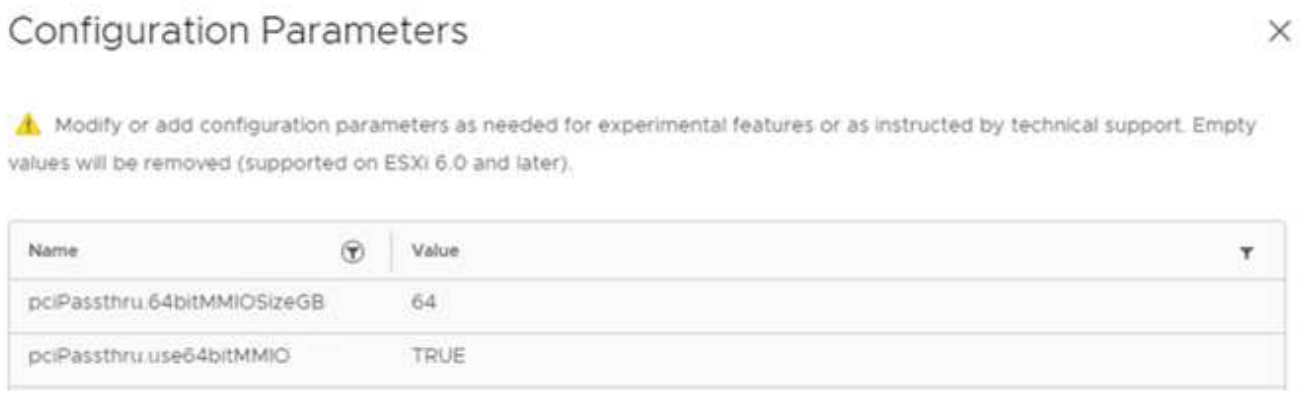

13. 在 vCenter 中将 vGPU 作为新的 PCI 设备添加到虚拟机时，请确保选择 NVIDIA GRID vGPU 作为 PCI 设备类型。
14. 选择适合所用 GPU ， GPU 内存和使用目的的正确 GPU 配置文件：例如，图形与计算。

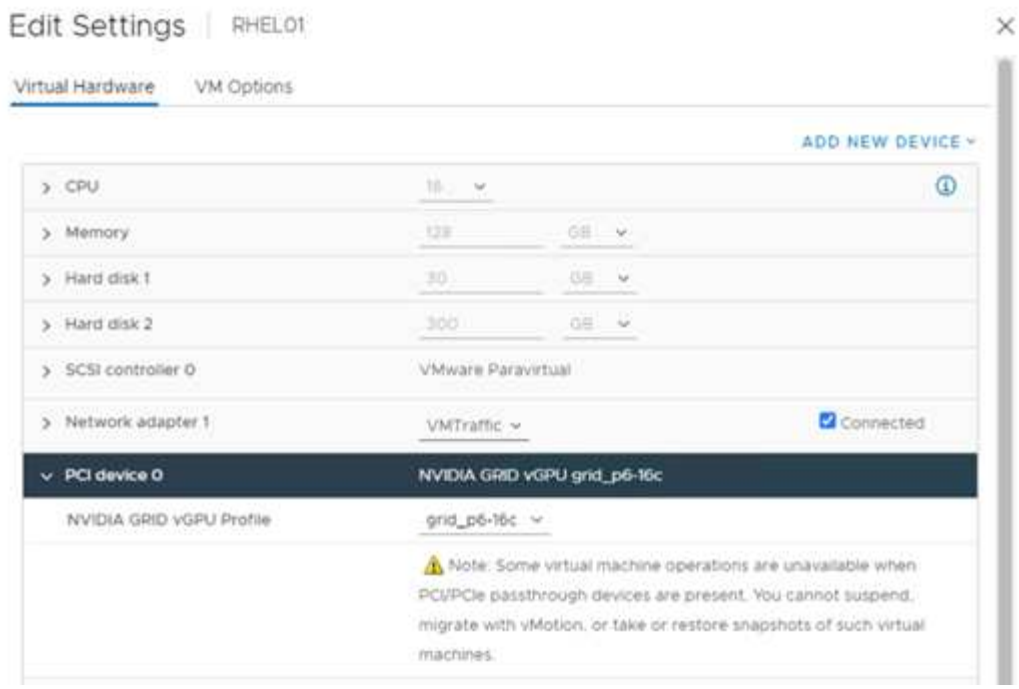

15. 在 RedHat Linux VM 上，可以运行以下命令来安装 NVIDIA 驱动程序：

```
[root@genomics1 genomics]#sh NVIDIA-Linux-x86_64-460.73.01-grid.run
```

16. 运行以下命令，验证是否报告了正确的 vGPU 配置文件：

```
[root@genomics1 genomics]# nvidia-smi -query-gpu=gpu_name
-format=csv,noheader -id=0 | sed -e 's/ /-/g'
GRID-P6-16C
[root@genomics1 genomics]#
```

17. 重新启动后，验证是否报告了正确的 NVIDIA vGPU 以及驱动程序版本。

```
[root@genomics1 genomics]# nvidia-smi
Wed Aug 18 20:30:56 2021
+-----------------------------------------------------------------------------
------+
| NVIDIA-SMI 460.73.01    Driver Version: 460.73.01    CUDA Version:
11.2     |
|-------------------------------+----------------------
+----------------------+
| GPU  Name        Persistence-M| Bus-Id        Disp.A | Volatile
Uncorr. ECC |
| Fan  Temp  Perf  Pwr:Usage/Cap|         Memory-Usage | GPU-Util
Compute M. |
|                               |                      |
MIG M. |
|===============================+======================+================
======|
|   0  GRID P6-16C         On   | 00000000:02:02.0 Off |
N/A |
| N/A   N/A    P8    N/A /  N/A |   2205MiB / 16384MiB |      0%
Default |
|                               |                      |
N/A |
+-------------------------------+----------------------
+----------------------+
+-----------------------------------------------------------------------------
------+
| Processes:
|
|  GPU   GI   CI        PID   Type   Process name                  GPU
Memory |
|        ID   ID                                                   Usage
|
|=============================================================================
======|
|    0   N/A  N/A      8604      G   /usr/libexec/Xorg
13MiB |
+-----------------------------------------------------------------------------
------+
[root@genomics1 genomics]#
```

18. 确保已在 vGPU 网格配置文件中的 VM 上配置许可证服务器 IP 。
    a. 复制模板。

```
[root@genomics1 genomics]# cp /etc/nvidia/gridd.conf.template
/etc/nvidia/gridd.conf
```

b. 编辑文件 ` /etc/nvidia/rid` ，添加许可证服务器 IP 地址，并将功能类型设置为 1 。

```
ServerAddress=192.168.169.10
```

```
FeatureType=1
```

19. 重新启动虚拟机后，您应在许可证服务器中的 " 已许可客户端 " 下看到一个条目，如下所示。

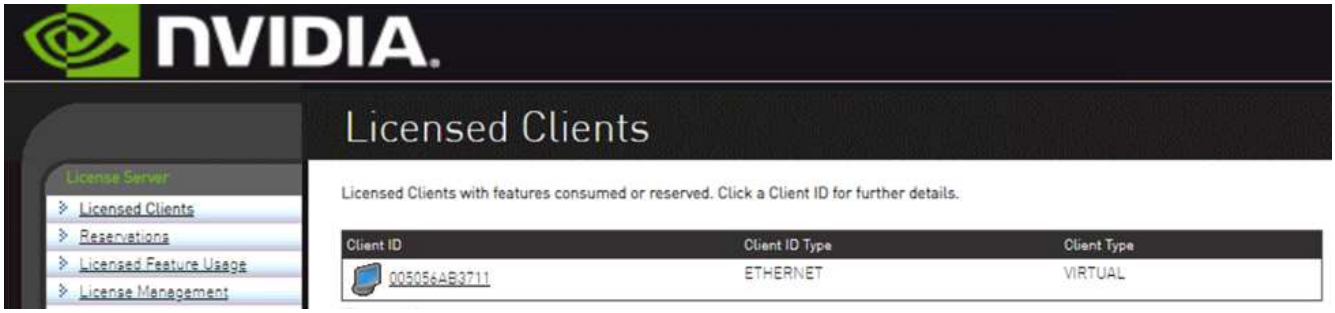

20. 有关下载 GATK 和 Cromwell 软件的详细信息，请参见 " 解决方案设置 " 一节。
21. 在 GATK 可以在内部使用 GPU 之后，工作流问题描述语言为 ` * 。WDL` 具有运行时属性，如下所示。

```
task ValidateBAM {
  input {
    # Command parameters
    File input_bam
    String output_basename
    String? validation_mode
    String gatk_path
    # Runtime parameters
    String docker
    Int machine_mem_gb = 4
    Int addtional_disk_space_gb = 50
  }
  Int disk_size = ceil(size(input_bam, "GB")) + addtional_disk_space_gb
  String output_name = "${output_basename}_${validation_mode}.txt"
  command {
    ${gatk_path} \
      ValidateSamFile \
      --INPUT ${input_bam} \
      --OUTPUT ${output_name} \
      --MODE ${default="SUMMARY" validation_mode}
  }
  runtime {
    gpuCount: 1
    gpuType: "nvidia-tesla-p6"
    docker: docker
    memory: machine_mem_gb + " GB"
    disks: "local-disk " + disk_size + " HDD"
  }
  output {
    File validation_report = "${output_name}"
  }
}
```

"接下来：总结。"

结论

"上一步： GPU 设置。"

全球许多医疗保健组织都将 FlexPod 作为一个通用平台进行了标准化。借助 FlexPod ，您可以放心地部署医疗保健功能。采用 NetApp ONTAP 的 FlexPod 标配，能够即装即用地实施一组行业领先的协议。无论对给定患者运行基因组学的请求来自何处， FlexPod 平台都标配了互操作性，可访问性，可用性和可扩展性。在 FlexPod 平台上实现标准化后，创新文化将具有传染性。

从何处查找追加信息

要了解有关本文档所述信息的更多信息，请查看以下文档和网站：

- 适用于 AI/ML 的 FlexPod 数据中心与适用于深度学习的 Cisco UCS 480 ML

  "https://www.cisco.com/c/en/us/td/docs/unified_computing/ucs/UCS_CVDs/flexpod_480ml_aiml_deployment.pdf"

- 采用 VMware vSphere 7.0 和 NetApp ONTAP 9.7 的 FlexPod Datacenter

  "https://www.cisco.com/c/en/us/td/docs/unified_computing/ucs/UCS_CVDs/fp_vmware_vsphere_7_0_ontap_9_7.html"

- ONTAP 9 文档中心

  "http://docs.netapp.com"

- 敏捷高效— FlexPod 如何推动数据中心现代化

  "https://www.flexpod.com/idc-white-paper/"

- 医疗保健领域的人工智能

  "https://www.netapp.com/us/media/na-369.pdf"

- FlexPod for HealthCare 可帮助您轻松实现转型

  "https://flexpod.com/solutions/verticals/healthcare/"

- Cisco 和 NetApp 的 FlexPod

  "https://flexpod.com/"

- 适用于医疗保健的 AI 和分析（NetApp）

  "https://www.netapp.com/us/artificial-intelligence/healthcare-ai-analytics/index.aspx"

- 医疗保健智能基础架构选择中的人工智能有助于取得更大成功

  https://www.netapp.com/pdf.html?item=/media/7410-wp-7314.pdf

- 采用 ONTAP 9.8 的 FlexPod 数据中心，适用于 Cisco Intersight 的 ONTAP 存储连接器和 Cisco Intersight 托管模式。

  https://www.netapp.com/pdf.html?item=/media/25001-tr-4883.pdf

- 采用 Red Hat Enterprise Linux OpenStack Platform 的 FlexPod Datacenter

  "https://www.cisco.com/c/en/us/td/docs/unified_computing/ucs/UCS_CVDs/flexpod_openstack_osp6.html"

版本历史记录

version	Date	文档版本历史记录
版本 1.0	2021年11月	初始版本。

版权信息

版权所有©2022 NetApp、Inc.。保留所有权利。Printed in the U.S.版权所涵盖的本文档的任何部分不得以任何形式或任何手段复制、包括影印、录制、 磁带或存储在电子检索系统中—未经版权所有者事先书面许可。

Software derived from copyrighted NetApp material is subject to the following license and disclaimer:

本软件由NetApp按"原样"提供、不含任何明示或默示担保、包括但不限于适销性和特定用途适用性的默示担保、特此声明不承担任何责任。IN NO EVENT SHALL NETAPP BE LIABLE FOR ANY DIRECT, INDIRECT, INCIDENTAL, SPECIAL, EXEMPLARY, OR CONSEQUENTIAL DAMAGES (INCLUDING, BUT NOT LIMITED TO, PROCUREMENT OF SUBSTITUTE GOODS OR SERVICES; LOSS OF USE, DATA, OR PROFITS; OR BUSINESS INTERRUPTION) HOWEVER CAUSED AND ON ANY THEORY OF LIABILITY, WHETHER IN CONTRACT, STRICT LIABILITY, OR TORT (INCLUDING NEGLIGENCE OR OTHERWISE) ARISING IN ANY WAY OUT OF THE USE OF THIS SOFTWARE, EVEN IF ADVISED OF THE POSSIBILITY OF SUCH DAMAGE.

NetApp reserves the right to change any products described herein at any time, and without notice.NetApp assumes no responsibility or liability arising from the use of products described herein, except as expressly agreed to in writing by NetApp.The use or purchase of this product does not convey a license under any patent rights, trademark rights, or any other intellectual property rights of NetApp.

The product described in this manual may be protected by one or more U.S.patents, foreign patents, or pending applications.

RESTRICTED RIGHTS LEGEND: Use, duplication, or disclosure by the government is subject to restrictions as set forth in subparagraph (c)(1)(ii) of the Rights in Technical Data and Computer Software clause at DFARS 252.277-7103 (October 1988) and FAR 52-227-19 (June 1987).

商标信息

NetApp、NetApp标识和中列出的标记 http://www.netapp.com/TM 是NetApp、Inc.的商标。其他公司和产品名称可能是其各自所有者的商标。